

UNIVERSIDAD CENTROAMERICANA
JOSÉ SIMEÓN CAÑAS



SISTEMA DE GENERACIÓN AUMENTADA POR RECUPERACIÓN
(RAG) BASADO EN DATOS VECTORIALES PARA
CONTEXTUALIZACIÓN DE DIAGNÓSTICOS TÉCNICOS: CASO DE
ESTUDIO EN SISTEMAS DE CLIMATIZACIÓN SPLIT

TRABAJO DE GRADUACIÓN PREPARADO PARA LA
FACULTAD DE INGENIERÍA Y ARQUITECTURA

PARA OPTAR AL GRADO DE
INGENIERA INFORMÁTICA

POR:

MARIO ANTONIO MARTINEZ VILLATORO
RODRIGO ANDRÉS MENA CABALLERO
DUGLAS FERNANDO PINEDA FUENTES

OCTUBRE 2026
ANTIGUO CUSCATLÁN, EL SALVADOR, C.A.

RECTOR
MARIO ERNESTO CORNEJO MENA, S.J.

SECRETARIA GENERAL
LIDIA GABRIELA BOLAÑOS TEODORO

DECANO DE LA FACULTAD DE INGENIERÍA Y ARQUITECTURA
CARLOS ERNESTO RIVAS CERNA

DIRECTOR DE LA CARRERA DE INGENIERÍA INFORMÁTICA
JOSÉ ENMANUEL AMAYA ARAÚJO

DIRECTOR DEL TRABAJO
JAMES EDWARD HUMBERSTONE MORALES

LECTORA
MARLENE ELIZABETH AGUILAR NAVARRO

AGRADECIMIENTOS

Expresamos nuestro más sincero agradecimiento a nuestro director del trabajo de graduación, el Ing. James Edward Humberstone Morales. Su excelente labor como orquestador de este proyecto y su apoyo incondicional desde el primer día fueron fundamentales para el éxito de esta investigación. Gracias por su constante guía, por resolver cada una de nuestras dudas con paciencia y por brindarnos siempre las indicaciones precisas para llevar este sistema a buen término.

A la Universidad Centroamericana José Simeón Cañas (UCA), por abrirnos sus puertas y brindarnos una formación académica de excelencia, dotándonos de las herramientas integrales y profesionales necesarias para enfrentarnos a los retos del mundo laboral y tecnológico.

Un agradecimiento especial a los técnicos profesionales en climatización que colaboraron desinteresadamente en este proyecto. Su disposición para responder a nuestras entrevistas iniciales y su valiosa participación durante la rigurosa fase de pruebas del sistema RAG fueron piezas clave para validar y enriquecer la utilidad real de nuestra propuesta tecnológica.

Finalmente, damos las gracias a nuestras familias y amigos. Su aliento constante, comprensión y apoyo moral durante todos estos años de estudio han sido el motor que nos ha impulsado a superar cada obstáculo y alcanzar esta importante meta en nuestras vidas profesionales.

DEDICATORIA

Quiero expresar mi más profundo agradecimiento a todas las personas que me han acompañado a lo largo de este proceso, tanto en los momentos más felices como en los más difíciles, y que nunca permitieron que me rindiera ante los obstáculos que encontré en el camino.

A mi papá, por todo el esfuerzo que hizo para permitirme estudiar y por el apoyo que me brindó durante todos estos años. Gracias por preocuparte siempre por cómo avanzaba en este camino, por motivarme a seguir adelante y por haberme dado las herramientas y oportunidades necesarias para alcanzar esta meta.

A mi mamá, por ser la persona en quien siempre pude confiar. Gracias por escucharme sin juzgarme, por aconsejarme en los momentos de incertidumbre y por apoyarme en cada una de las decisiones que he tomado a lo largo de este camino.

A mi tía, quien desempeñó un papel fundamental durante esta etapa. Al venir de otro departamento, me abrió las puertas de su hogar y me brindó un espacio donde siempre me sentí cómodo, acompañado y bien recibido. Gracias por su paciencia y apoyo durante todos estos años.

A mi hermano, por ser mi confidente y mi mayor apoyo en muchos momentos. Gracias por estar siempre dispuesto a escucharme, comprenderme y aconsejarme cuando más lo necesité, sin importar las circunstancias.

A mi perrito Jack, quien desde pequeño ha sido una fuente constante de tranquilidad y alegría. Gracias por acompañarme en los momentos de mayor estrés y por brindarme la paz necesaria para seguir adelante cuando las dificultades parecían superar mis fuerzas.

A todos mis amigos, quienes han sido un pilar fundamental en mi vida. Gracias por compartir conmigo gran parte de este proceso, por las experiencias vividas, por las palabras de ánimo y por hacer más llevaderos aquellos momentos en los que el camino parecía incierto.

También dedico este logro a mí mismo, por la perseverancia, el esfuerzo y la determinación que me permitieron superar los desafíos encontrados en el camino. Por no rendirme ante las dificultades, por seguir adelante incluso en los momentos de incertidumbre y por mantener siempre la convicción de alcanzar esta meta.

Hoy culmina una etapa muy importante de mi vida, marcada por aprendizajes, desafíos y experiencias que me han permitido crecer tanto personal como profesionalmente. Gracias a todos quienes formaron parte de este camino.

Mario Antonio Martinez Villatoro

DEDICATORIA

Quiero expresar mi más profundo agradecimiento a mis padres, quienes son los principales responsables de que haya tenido la oportunidad de cursar esta carrera. Gracias por su arduo esfuerzo para brindarme siempre los mejores recursos y por respaldar incondicionalmente mis intereses y aspiraciones académicas y profesionales.

A mi mamá, por ser mi principal pilar y apoyarme en cada una de mis decisiones. Gracias por tu inmensa empatía y comprensión, pero, sobre todo, por el enorme sacrificio de haberte mudado a la ciudad conmigo desde el primer día para hacer posible mi sueño de estudiar.

A mi papá, por estar para mí en toda circunstancia. Sin importar el momento o el motivo, siempre he contado con tu apoyo constante y tu mano extendida cuando más lo he necesitado.

A mi hermana, por ser mi gran inspiración y un modelo a seguir a lo largo de toda mi vida, especialmente en el ámbito académico. Gracias por abrir brecha y hacer que mi propio camino fuera más sencillo. Asimismo, a mi hermano, por su apoyo incondicional y por estar dispuesto a ayudarme siempre que se lo pedí.

A mi pareja, por su acompañamiento constante en mi desarrollo educativo y profesional. Gracias por impulsarme a alcanzar mi máximo nivel y por confiar siempre plenamente en mi potencial.

A mi mascota Appa, a quien adopté desde el inicio de la universidad, por ser un compañero leal y por brindarme alegría y paz mental en los momentos de mayor estrés y dificultad durante todo este proceso.

A mis amigos, por ser siempre un refugio frente a la presión, y por brindarme en todo momento una amistad sincera y auténtica.

Finalmente, a todos los profesores que dejaron una huella en mi formación; gracias por marcar mi desarrollo no solo a nivel educativo, sino fundamentalmente en mi crecimiento como ser humano.

Rodrigo Andrés Mena Caballero

DEDICATORIA

Dedico este trabajo a todas las personas que me han ayudado a llegar hasta este punto: A mis padres, Mario y Evelyn, mis hermanas, Ale y Andrea, y el resto de familiares y amigos.

Duglas Fernando Pineda Fuentes

RESUMEN

Los Modelos de Lenguaje de Gran Escala (LLM) han transformado el acceso a la información, pero presentan una limitación estructural al operar sobre dominios técnicos altamente especializados: carecen de acceso dinámico a la documentación de referencia y tienden a generar respuestas plausibles pero incorrectas, fenómeno conocido como alucinación. El presente trabajo aborda dicho problema mediante el diseño e implementación de un sistema de Generación Aumentada por Recuperación (RAG), arquitectura que acopla un mecanismo de recuperación semántica sobre una base de datos vectorial con un modelo generativo, de modo que cada respuesta se fundamenta exclusivamente en el contexto documental recuperado y no en el conocimiento paramétrico del modelo.

El núcleo de la investigación reside en la construcción y evaluación empírica del *pipeline* de orquestación implementado sobre el *framework* LlamaIndex, responsable de coordinar la ingesta documental, el particionado (*chunking*), la generación de *embeddings* semánticos y su indexación en la base de datos vectorial ChromaDB. Se documentan las decisiones de ingeniería de datos que determinan la calidad de la recuperación: la comparación entre la ingesta de PDF nativo y texto plano pre-extraído, en la que el formato nativo preservó el 100 % de la integridad semántica de las fichas técnicas frente al 0–20 % obtenido con texto plano; y el *benchmarking* de modelos de *embeddings*, en el que el modelo multilingüe Gemini Embedding 001 alcanzó una tasa de recuperación (*hit rate*) del 80 %, superando en 60 puntos porcentuales a los modelos monolingües de código abierto evaluados, incapaces de mapear consultas en español contra un corpus técnico en inglés.

Un eje central del trabajo es la caracterización y mitigación de la alucinación por transferencia de dominio, comportamiento en el que el sistema sintetiza con confianza un procedimiento aparentemente válido a partir de fragmentos semánticamente próximos pero pertenecientes a un equipo fuera del alcance del corpus indexado. Se demuestra que el anclaje de la generación al contexto recuperado, junto con la configuración de *prompts* de sistema y estrategias de síntesis diferenciadas (*tree_summarize* y *compact*), reduce este riesgo, y se dimensiona su alcance residual como línea prioritaria de trabajo futuro mediante *guardrails* de validación previa a la generación.

Como caso de estudio para validar empíricamente las métricas de *hit rate* y precisión del sistema, se seleccionó el dominio del diagnóstico técnico de aires acondicionados tipo Split, empleando como corpus manuales de servicio oficiales de los fabricantes Daikin, Mabe y Toshiba. La evaluación con cinco técnicos activos del sector confirmó una tasa de respuestas correctas del 93 % y una tasa de citación explícita de la fuente documental del 87 %, validando que la arquitectura RAG propuesta entrega respuestas trazables al documento fuente en condiciones reales de uso.

ÍNDICE

RESUMEN	i
ÍNDICE DE FIGURAS	v
ÍNDICE DE TABLAS	vi
SIGLAS	ix
CAPÍTULO 1. INTRODUCCIÓN	1
1.1 Planteamiento del problema	1
1.2 Antecedentes	1
1.3 Alcances y limitaciones	2
1.3.1 Alcances	2
1.3.2 Limitaciones	3
1.4 Objetivos	3
1.4.1 Objetivo general	3
1.4.2 Objetivos específicos	3
CAPÍTULO 2. MARCO DE ANTECEDENTES	5
2.1 Implementaciones de Sistemas de Generación Aumentada por Recuperación	5
2.2 Modelos de <i>Embeddings</i> y Bases de Datos Vectoriales	6
2.3 Gestión del Conocimiento Técnico y Documentación No Estructurada	6
CAPÍTULO 3. MARCO TEÓRICO	7
3.1 Procesamiento de Lenguaje Natural (PLN)	7
3.2 Modelos de Lenguaje de Gran Escala (LLM) y Arquitectura Transformer	7
3.2.1 Limitaciones de los LLM Tradicionales y Problema de Alucinación	8
3.3 Embeddings y Representación Semántica	8
3.4 Bases de Datos Vectoriales y Búsqueda Semántica	9
3.5 Generación Aumentada por Recuperación (RAG)	9
3.6 Framework LlamaIndex	11
CAPÍTULO 4. METODOLOGÍA	13
4.1 Enfoque Metodológico	13
4.2 Comprensión del Problema	13
4.3 Comprensión de los Datos	14
4.4 Modelado de Datos	15
4.4.1 Implementación de Recuperación Multimodal Híbrida	17
4.4.2 Estrategia de Ingesta Escalable	18
4.4.3 Gestión de Estado y Persistencia	19
CAPÍTULO 5. PRESENTACIÓN, ANÁLISIS E INTERPRETACIÓN DE RESULTADOS	21

5.1	Resultados de la Evaluación con Usuarios Finales	21
5.1.1	Métricas de Usabilidad e Integración del Flujo de Trabajo	21
5.1.2	Métricas de Calidad de las Respuestas	22
5.1.3	Análisis Crítico: Polarización en la Comprensión de Consultas	24
5.1.4	Métricas de Seguridad y Diferenciación de Perfil Técnico	25
5.2	Casos de Uso y Verificación Funcional	25
5.2.1	Desempeño ante Preguntas Comunes	25
5.2.2	Desempeño ante Preguntas Específicas	26
5.2.3	Impacto en la Productividad del Técnico	27
5.3	Limitaciones del Sistema y Casos Borde	27
5.3.1	Límite de Cuota y Degradación ante Carga Masiva	27
5.3.2	Alucinación por Transferencia de Dominio	28
5.3.3	Limitante Multimodal	28
CAPÍTULO 6. CONCLUSIONES Y RECOMENDACIONES		31
6.1	Conclusiones	31
6.2	Recomendaciones	32
6.2.1	Integración de Modelos de Lenguaje Multimodales Nativos	32
6.2.2	Implementación de Preguntas de Retroalimentación Interactiva	32
6.2.3	Desarrollo de <i>Guardrails</i> de Seguridad para Prevenir Alucinaciones por Transferencia de Dominio	33
REFERENCIAS		35

ANEXOS

- ANEXO A. Catálogo de Fallas Comunes en Aires Acondicionados tipo Split
- ANEXO B. Instrumento de Evaluación y Transcripciones de Entrevistas
- ANEXO C. Diseño Final de la Interfaz de Usuario

ÍNDICE DE FIGURAS

Figura 3.1	Arquitectura del Sistema de Generación Aumentada por Recuperación (RAG). Fuente: [Elaboración propia]	10
Figura 4.1	Arquitectura Final del Sistema RAG para diagnóstico de HVAC. Vista 1: capas de usuario y backend	15
Figura 4.2	Arquitectura Final del Sistema RAG para diagnóstico de HVAC. Vista 2: motor RAG, persistencia y servicios externos	16
Figura 5.1	Distribución de respuestas por dimensión de calidad.....	23
Figura 5.2	Distribución de respuestas para el ítem “El asistente entendió correctamente las preguntas realizadas”	24
Figura 5.3	Distribución de respuestas en métricas de seguridad y diferenciación de perfil técnico	25

ÍNDICE DE TABLAS

Tabla 5.1	Distribución de respuestas Likert del instrumento de evaluación del prototipo	22
-----------	---	----

SIGLAS

BTU:	Unidad Térmica Británica (<i>British Thermal Unit</i>)
CRISP-DM:	<i>Cross-Industry Standard Process for Data Mining</i>
FIA:	Facultad de Ingeniería y Arquitectura
HVAC:	Calefacción, Ventilación y Aire Acondicionado (<i>Heating, Ventilation and Air Conditioning</i>)
IA:	Inteligencia Artificial
LLM:	Modelos de Lenguaje de Gran Escala (<i>Large Language Models</i>)
NTC:	Coeficiente de Temperatura Negativo (<i>Negative Temperature Coefficient</i>)
OCR:	Reconocimiento Óptico de Caracteres (<i>Optical Character Recognition</i>)
PLN:	Procesamiento de Lenguaje Natural
RAG:	Generación Aumentada por Recuperación (<i>Retrieval-Augmented Generation</i>)
UCA:	Universidad Centroamericana José Simeón Cañas

CAPÍTULO 1. INTRODUCCIÓN

1.1 Planteamiento del problema

El acceso a información técnica especializada constituye un problema recurrente en los dominios donde el conocimiento crítico se encuentra distribuido en documentación extensa y no estructurada, como los manuales de servicio en formato PDF. En el sector del mantenimiento de sistemas de aire acondicionado tipo Split, ese conocimiento —códigos de error, diagramas y procedimientos de diagnóstico— se dispersa en manuales que pueden superar las cien páginas, cuya consulta manual toma en promedio entre uno y más de cinco minutos por búsqueda, según se constató en las entrevistas realizadas a profesionales del sector¹. No obstante, la dificultad de fondo no es de naturaleza mecánica, sino informática: reside en la ineficiencia de la búsqueda indexada tradicional sobre documentos no estructurados y en la falta de precisión de las respuestas generativas cuando carecen de un sistema de recuperación acoplado.

Los Modelos de Lenguaje de Gran Escala (LLM) de propósito general, a los que los técnicos recurren para agilizar sus diagnósticos, presentan dos limitaciones estructurales que agravan el problema. En primer lugar, no disponen de acceso dinámico a la documentación oficial de cada fabricante, por lo que sus respuestas se apoyan en el conocimiento estadístico adquirido durante el entrenamiento y resultan generales, redundantes o descontextualizadas respecto al equipo consultado. En segundo lugar, ante la ausencia de un contexto de recuperación optimizado, incurren en alucinaciones: generan información plausible pero incorrecta o no respaldada por una fuente verificable, comportamiento especialmente riesgoso en un dominio técnico donde una recomendación errónea puede derivar en daños al equipo o en riesgos para la integridad del técnico.

El problema central que motiva el presente trabajo radica, por tanto, en la necesidad de acotar y contextualizar el conocimiento de un modelo generativo mediante un mecanismo de recuperación semántica que garantice que cada respuesta se fundamente exclusivamente en documentación verificable. El diagnóstico de aires acondicionados tipo Split se adopta como caso de estudio concreto para validar dicho mecanismo, dado que reúne las condiciones que hacen crítico el problema: un corpus técnico voluminoso, la exigencia de exactitud por fabricante y la necesidad de trazabilidad documental en cada respuesta.

1.2 Antecedentes

Las entrevistas realizadas a tres profesionales con perfiles variados y entre seis meses y tres años y medio de experiencia, con formación tanto técnica formal como empírica, validaron la magnitud del problema descrito (véase Anexo B). La totalidad de los entrevistados ha recurrido a herramientas

¹Las transcripciones completas de las entrevistas se encuentran en el Anexo B.

de inteligencia artificial para apoyar sus diagnósticos, calificándolas entre siete y diez sobre diez en confiabilidad. No obstante, a pesar de esta valoración positiva, coinciden en señalar sus limitaciones de forma contundente: un técnico con tres años y medio de experiencia que paga una suscripción a una herramienta de IA y le carga manuales directamente reportó que la herramienta “se mantiene en el mismo círculo sin profundizar más”, mientras que otro profesional con tres años de trayectoria advirtió que actuar con información descontextualizada respecto al fabricante genera diagnósticos erróneos, evidenciando un riesgo operativo real.

Este déficit también se refleja en la productividad: el técnico con mayor carga de trabajo atiende entre siete y ocho equipos diarios y señaló que los retrasos por búsqueda de información afectan considerablemente los servicios siguientes, en tanto que otro entrevistado indicó que, en casos de alta complejidad, la ausencia de datos técnicos a la mano puede reducir la atención a un único equipo en toda la jornada.

Ante este escenario, los tres profesionales manifestaron de forma unánime su interés en un asistente especializado que muestre el fragmento exacto del documento, proporcione pasos numerados e incluya diagramas técnicos; características que, según los entrevistados, eliminarían la ambigüedad de las respuestas genéricas y reducirían el margen de error en diagnósticos que exigen valores precisos de voltaje, resistencia o configuración de sensores. Esta necesidad operativa no resuelta constituye el antecedente directo que motiva el presente proyecto.

1.3 Alcances y limitaciones

1.3.1 Alcances

Para dar respuesta a la necesidad operativa de agilizar los diagnósticos técnicos, el proyecto se centra en el diseño y desarrollo de un prototipo funcional basado en la arquitectura de Generación Aumentada por Recuperación (RAG). El ámbito de aplicación abarca exclusivamente los sistemas de aire acondicionado tipo Split de muro o pared, instalados en entornos residenciales y comerciales ligeros. Específicamente, el asistente brindará soporte para equipos con tecnología Inverter y convencional que operen dentro de un rango de capacidad térmica de 9,000 a 24,000 BTU.

A nivel de hardware, el marco de diagnóstico de la herramienta contempla el análisis de los componentes principales que estructuran estos equipos: la unidad interior, la unidad exterior, los sistemas de control, los sensores de temperatura y el sistema de drenaje. Para asegurar la viabilidad del desarrollo dentro de los plazos establecidos, el dominio operativo se acota a la resolución de exactamente diecinueve fallas comunes y repetibles asociadas a dichos componentes, cuyo listado exhaustivo y categorización se documentan en el Anexo A.

El motor de conocimiento del sistema se alimenta mediante un corpus técnico compuesto en su totalidad por manuales de servicio oficiales. Como resultado final, se construye un prototipo de software funcional, accesible a través de una interfaz de usuario (cuyo diseño preliminar se ilustra en el Anexo C), capaz de procesar consultas formuladas en lenguaje natural. Este aplicativo genera hipótesis de causa, secuencias de pasos para el diagnóstico y recomendaciones de mantenimiento básico, garantizando en todo momento la referenciación exacta del fragmento documental de origen que fundamenta la respuesta.

1.3.2 Limitaciones

- **No entrenamiento de modelos fundacionales:** El sistema no entrenará Modelos de Lenguaje de Gran Escala (LLM) desde cero; la solución integrará modelos preentrenados mediante el uso de frameworks existentes.
- **Ausencia de autonomía de diagnóstico:** El sistema no actuará como una entidad de diagnóstico autónoma; operará estrictamente como un asistente de apoyo para acelerar la búsqueda de información, mientras que la toma de decisiones finales recaerá siempre en el criterio del técnico humano.
- **Respaldo documental obligatorio:** El prototipo no generará recomendaciones empíricas ni respuestas que carezcan de un respaldo documental explícito dentro de la base de datos vectorial.

1.4 Objetivos

1.4.1 Objetivo general

Desarrollar un prototipo de asistente interactivo basado en la arquitectura RAG para optimizar el diagnóstico y la resolución de problemas, mediante consultas en lenguaje natural sobre corpus documentales técnicos.

1.4.2 Objetivos específicos

- Diseñar el pipeline de recuperación semántica del sistema RAG, definiendo las estrategias de ingesta y particionado (chunking) del corpus documental técnico.
- Construir la base de datos vectorial del sistema, seleccionando mediante benchmarking el modelo de embeddings multilingüe con mayor tasa de recuperación sobre el corpus técnico.
- Configurar la estrategia de generación aumentada y los prompts de sistema orientados a acotar el contexto de recuperación y mitigar las alucinaciones por transferencia de dominio de los modelos de lenguaje.
- Construir un repositorio documental curado a partir de manuales técnicos de servicio, reportes de fallas y registros históricos de los fabricantes.

- Integrar un modelo de lenguaje que genere recomendaciones basadas exclusivamente en la información recuperada de las fuentes documentales oficiales.
- Evaluar el sistema en términos de utilidad, precisión percibida y reducción del esfuerzo y tiempo de búsqueda manual frente a los métodos tradicionales.
- Diseñar el instrumento de evaluación para la encuesta a los usuarios finales.

CAPÍTULO 2. MARCO DE ANTECEDENTES

El presente capítulo sitúa la propuesta dentro del estado del arte de la Generación Aumentada por Recuperación mediante la revisión y el análisis de investigaciones previas. Se examinan cuatro líneas de trabajo directamente relacionadas con el objeto de estudio: las implementaciones documentadas de sistemas RAG, el desarrollo de modelos de *embeddings* y bases de datos vectoriales como sustrato de la recuperación semántica, la aplicación de estas tecnologías a la gestión del conocimiento técnico especializado y, finalmente, la evidencia empírica sobre el problema de la alucinación que dichos sistemas buscan mitigar. Esta fundamentación proporciona el sustento científico que respalda las decisiones de diseño adoptadas en el proyecto.

2.1 Implementaciones de Sistemas de Generación Aumentada por Recuperación

La arquitectura de Generación Aumentada por Recuperación fue formalizada por Lewis et al. (2020), quienes propusieron acoplar un recuperador de pasajes basado en representaciones densas a un modelo generativo, demostrando mejoras significativas en tareas intensivas en conocimiento respecto a los modelos puramente paramétricos. Este trabajo estableció el paradigma que separa el conocimiento almacenado de forma no paramétrica en un índice recuperable del conocimiento paramétrico aprendido durante el entrenamiento, principio que constituye la base conceptual del sistema desarrollado en la presente investigación.

A partir de dicho fundamento, la literatura reciente ha explorado la optimización sistemática de estos sistemas. Ammar et al. (2025) analizaron el impacto de los hiperparámetros del *pipeline* RAG —tales como el tamaño de fragmento, el número de pasajes recuperados y el modelo de *embeddings*— sobre el rendimiento y la eficiencia, evidenciando que las decisiones de configuración en la etapa de recuperación condicionan de forma determinante la calidad de la respuesta generada. Esta observación es coherente con el enfoque iterativo de experimentación adoptado en el modelado del presente prototipo.

En el plano aplicado, Krütli y Hanne (2025) implementaron un sistema RAG para la recuperación segura de información en el dominio de la construcción y la gestión de instalaciones, un contexto análogo al del mantenimiento técnico por cuanto opera sobre documentación normativa extensa y exige trazabilidad de las fuentes. Sus resultados confirman que el anclaje de las respuestas en un corpus documental controlado incrementa la fiabilidad de la información entregada frente a los modelos de propósito general, validando la pertinencia de la arquitectura para dominios técnicos especializados.

2.2 Modelos de *Embeddings* y Bases de Datos Vectoriales

La representación vectorial del lenguaje tiene su origen en los modelos de *embeddings* estáticos propuestos por Mikolov et al. (2013), que demostraron la capacidad de capturar relaciones semánticas entre términos mediante su proximidad en un espacio vectorial continuo. Este principio evolucionó hacia los *embeddings* contextuales generados por arquitecturas Transformer, que constituyen el estándar actual para la recuperación semántica sobre documentos.

En el terreno de los modelos multilingües, Lee et al. (2025) presentaron la familia Gemini Embedding, cuyo entrenamiento sobre corpus masivos en múltiples idiomas habilita el mapeo semántico entre consultas y documentos redactados en lenguas distintas. Esta capacidad resulta crítica para escenarios como el del presente proyecto, en el que las consultas se formulan en español mientras que el corpus técnico se encuentra mayoritariamente en inglés, condición que descalifica a los modelos monolingües de código abierto. La selección del modelo de *embeddings* y su almacenamiento en una base de datos vectorial de código abierto, evaluada en función del balance entre velocidad de recuperación y calidad de representación (Ammar et al., 2025), conforman el sustrato técnico sobre el que opera la búsqueda por similitud del sistema.

2.3 Gestión del Conocimiento Técnico y Documentación No Estructurada

Un antecedente relevante para el proyecto es el tratamiento de la documentación técnica no estructurada como fuente de conocimiento recuperable. Zhang et al. (2024) demostraron que la calidad del proceso de extracción documental incide directamente en el rendimiento de los sistemas RAG, al cuantificar el impacto en cascada que introduce el reconocimiento óptico de caracteres sobre la recuperación y la generación. Este hallazgo sustenta la decisión metodológica de priorizar la ingesta de documentos en formato PDF nativo sobre las alternativas basadas en texto extraído, adoptada en la fase de preparación de los datos.

La evidencia acumulada respalda igualmente la necesidad de mecanismos de recuperación acoplados para contener el fenómeno de la alucinación. Shuster et al. (2021) demostraron empíricamente que la augmentación por recuperación reduce de forma significativa la generación de información no factual en sistemas conversacionales, al anclar las respuestas en evidencia documental verificable. En la misma dirección, los estudios de Ji et al. (2023) y Anh-Hoang et al. (2025) sistematizan el origen de las alucinaciones en los modelos de lenguaje, atribuyéndolas tanto a las estrategias de *prompting* como al comportamiento intrínseco del modelo, y coinciden en señalar la incorporación de contexto externo verificable como una de las estrategias de mitigación más efectivas. Este conjunto de antecedentes fundamenta el enfoque del presente trabajo, orientado a contextualizar la generación mediante recuperación semántica para garantizar la trazabilidad y la exactitud de las respuestas en un dominio técnico crítico.

CAPÍTULO 3. MARCO TEÓRICO

Este capítulo presenta los fundamentos teóricos y las tecnologías subyacentes que sustentan el diseño e implementación del asistente inteligente. Se abordan los conceptos de Procesamiento de Lenguaje Natural, los Modelos de Lenguaje de Gran Escala y su arquitectura Transformer, el problema de la alucinación, la representación semántica mediante embeddings, las bases de datos vectoriales, la arquitectura de Generación Aumentada por Recuperación (RAG) y el framework LlamaIndex utilizado como capa de integración.

3.1 Procesamiento de Lenguaje Natural (PLN)

El Procesamiento de Lenguaje Natural (PLN) es una subdisciplina de la Inteligencia Artificial que estudia la interacción entre las computadoras y el lenguaje humano. Su objetivo principal es permitir que los sistemas computacionales comprendan, interpreten y generen lenguaje natural de forma significativa. El PLN combina técnicas de lingüística computacional, aprendizaje automático, modelado estadístico y redes neuronales profundas (Jurafsky & Martin, 2023).

En el contexto de sistemas técnicos, el PLN permite analizar documentación especializada (manuales de servicio, reportes técnicos, bitácoras) y convertir texto no estructurado en información procesable por un sistema inteligente.

Para el presente proyecto, el PLN es la base que permite interpretar preguntas formuladas por técnicos en lenguaje natural, comprender términos técnicos como códigos de error, voltajes, resistencias o configuraciones de sensores, y relacionar dichas consultas con fragmentos específicos de manuales oficiales.

3.2 Modelos de Lenguaje de Gran Escala (LLM) y Arquitectura Transformer

Los Modelos de Lenguaje de Gran Escala (Large Language Models, LLM) son modelos de aprendizaje profundo entrenados con grandes volúmenes de texto para predecir y generar lenguaje coherente (Brown et al., 2020).

La mayoría de los LLM modernos están basados en la arquitectura Transformer, introducida por Vaswani et al. (2017) en el artículo “Attention Is All You Need”. Esta arquitectura utiliza un mecanismo llamado autoatención (self-attention) que permite al modelo evaluar la relevancia de cada palabra respecto a las demás dentro de una secuencia.

Entre las características principales de los Transformers se encuentran el procesamiento paralelo de secuencias, la captura eficiente de dependencias de largo alcance y una mejor comprensión contextual

que los modelos recurrentes tradicionales.

Sin embargo, los LLM presentan limitaciones importantes: pueden generar información incorrecta (alucinaciones), no garantizan precisión técnica en dominios especializados y no tienen acceso dinámico a documentación específica salvo que se integre un sistema de recuperación externa.

En el contexto del diagnóstico de equipos tipo Split, depender únicamente de un LLM generalista puede producir respuestas ambiguas o no alineadas con especificaciones del fabricante.

3.2.1 Limitaciones de los LLM Tradicionales y Problema de Alucinación

Uno de los principales problemas documentados en los LLM es la alucinación, fenómeno en el que el modelo genera información plausible pero incorrecta o no respaldada por una fuente verificable (Ji et al., 2023).

En entornos técnicos críticos, como el diagnóstico eléctrico o electrónico, este comportamiento representa un riesgo operativo real, ya que decisiones incorrectas pueden provocar daños en componentes, generar diagnósticos erróneos, incrementar tiempos de reparación y afectar la seguridad del técnico.

Diversos estudios recientes (Ji et al., 2023; Lewis et al., 2020) han señalado que los LLM sin acceso a fuentes externas estructuradas tienden a completar respuestas con conocimiento estadístico aprendido durante el entrenamiento, lo cual no garantiza exactitud técnica específica por fabricante.

Por ello, surge la necesidad de integrar mecanismos de recuperación de información controlada.

3.3 Embeddings y Representación Semántica

Los embeddings son representaciones vectoriales de palabras, frases o documentos en un espacio matemático de múltiples dimensiones. Su propósito es capturar relaciones semánticas entre conceptos (Mikolov et al., 2013).

En lugar de representar texto como simples palabras clave, los embeddings permiten que términos conceptualmente similares se ubiquen cerca en el espacio vectorial. Por ejemplo, términos como “Sensor NTC”, “Termistor” y “Sensor de temperatura evaporador”, aunque no sean idénticos, pueden tener proximidad semántica en el espacio vectorial, permitiendo búsquedas más inteligentes.

Esta representación es clave para la búsqueda semántica, que supera la búsqueda tradicional basada en coincidencia exacta de palabras.

3.4 Bases de Datos Vectoriales y Búsqueda Semántica

Las bases de datos tradicionales (relacionales o NoSQL) están diseñadas para búsquedas estructuradas basadas en campos específicos o coincidencias exactas.

En contraste, las bases de datos vectoriales almacenan embeddings y permiten búsquedas por similitud utilizando métricas como la similitud coseno, la distancia euclidiana y el producto punto. Esto permite encontrar fragmentos de documentos que sean semánticamente relevantes aunque no compartan exactamente las mismas palabras.

En el caso de manuales técnicos extensos, una base vectorial permite dividir documentos en fragmentos, convertirlos en embeddings y recuperar únicamente los fragmentos más relevantes según la consulta del técnico. Esta tecnología es esencial para implementar sistemas de recuperación eficiente sobre documentación especializada.

3.5 Generación Aumentada por Recuperación (RAG)

La Generación Aumentada por Recuperación (Retrieval-Augmented Generation, RAG) es una arquitectura que combina un sistema de recuperación de información (base de datos vectorial) con un modelo generativo (LLM) (Lewis et al., 2020).

En lugar de depender únicamente del conocimiento interno del modelo, RAG permite que el LLM recupere primero fragmentos relevantes de documentos oficiales y genere una respuesta basada exclusivamente en ese contexto recuperado. Esto reduce significativamente el problema de alucinación y aumenta la precisión técnica.

En el proyecto propuesto, el flujo es el siguiente: el técnico formula una consulta, el sistema genera el embedding de la consulta, se buscan fragmentos relevantes en la base vectorial, el LLM genera una respuesta utilizando únicamente esos fragmentos y, finalmente, se muestra el fragmento exacto del manual como respaldo.

Este enfoque permite cumplir con el requisito identificado en las entrevistas: mostrar información específica del fabricante y pasos numerados directamente desde el manual. Como se ilustra en la Figura 3.1, el flujo del sistema se divide en una etapa de recuperación semántica y una etapa de generación fundamentada, ambas orquestadas por el framework LlamaIndex como capa de integración.




figure 3.1 Arquitectura del Sistema de Generación Aumentada por Recuperación (RAG). Fuente: [Elaboración propia]

3.6 Framework LlamaIndex

LlamaIndex es un framework diseñado para facilitar la integración entre fuentes de datos externas y modelos LLM (LlamaIndex, 2024). Su función principal es ingestar documentos, fragmentarlos, generar embeddings, indexarlos y conectarlos con modelos generativos.

De este modo, LlamaIndex permite construir aplicaciones basadas en arquitectura RAG de manera estructurada, facilitando la indexación de manuales técnicos, el control sobre las fuentes utilizadas y la generación de respuestas respaldadas por contexto verificable.

En este proyecto, LlamaIndex actúa como la capa intermedia que conecta los manuales de servicio con el modelo generativo y la base vectorial.

CAPÍTULO 4. METODOLOGÍA

4.1 Enfoque Metodológico

El presente proyecto de graduación tiene un enfoque académico y exploratorio, sin fines de implementación inmediata. No obstante, el sistema se diseña bajo criterios de escalabilidad y adaptabilidad, permitiendo su potencial aplicación en entornos empresariales relacionados con el mantenimiento de equipos de aire acondicionado tipo split.

Dada la naturaleza del presente proyecto, orientado al desarrollo de un sistema basado en generación aumentada por recuperación (RAG), resulta necesario establecer un enfoque metodológico que permita estructurar de manera sistemática las etapas de análisis, diseño y evaluación del sistema.

En este contexto, se selecciona la metodología Cross-Industry Standard Process for Data Mining (CRISP-DM), ampliamente utilizada en proyectos de minería de datos y ciencia de datos (Chapman et al., 2000), y reconocida por su enfoque iterativo y su énfasis en la comprensión del dominio del problema (Shearer, 2000).

Si bien no se identifican antecedentes específicos que documenten la aplicación de CRISP-DM en sistemas RAG, sus principios resultan compatibles con este tipo de soluciones, particularmente en lo relativo a la integración de datos, la construcción iterativa de modelos y la evaluación progresiva de resultados (Mariscal et al., 2010). Asimismo, los sistemas RAG combinan técnicas de recuperación de información y generación de lenguaje natural para resolver tareas intensivas en conocimiento, lo cual requiere un enfoque metodológico estructurado (Lewis et al., 2020).

4.2 Comprensión del Problema

Esta fase inicial se orientó a la comprensión del flujo de trabajo real y de las necesidades de los usuarios finales, con el propósito de delimitar el dominio del proyecto. Para ello, se diseñó un instrumento de investigación y se realizaron entrevistas a tres profesionales técnicos, cuyos niveles de experiencia oscilaron entre seis meses y tres años y medio, incluyendo tanto formación técnica formal como empírica.

El análisis de la información recolectada evidenció que la búsqueda manual de información técnica, como códigos de error, diagramas y procedimientos de diagnóstico, en documentación física o digital, es la etapa clave para la realización de un servicio de mantenimiento (Krütli & Hanne, 2025), estimando que se requiere entre uno y más de cinco minutos por consulta puntual. Este tiempo impacta directamente en la eficiencia operativa, generando retrasos en la prestación del servicio y una disminución en la productividad diaria.

Asimismo, se identificó que los técnicos recurren a herramientas de inteligencia artificial de propósito general, como ChatGPT, con el objetivo de agilizar sus procesos de diagnóstico. No obstante, dichas herramientas presentan limitaciones significativas (Anh-Hoang et al., 2025), tales como la generación de respuestas redundantes, ambiguas o carentes de contexto técnico específico por fabricante, lo cual introduce un riesgo operativo en escenarios reales de mantenimiento .

A partir de estos hallazgos, se delimitó el dominio del proyecto al diagnóstico preliminar y mantenimiento de sistemas de aire acondicionado tipo split de muro, enfocados en entornos residenciales y comerciales ligeros, con capacidades entre 9,000 y 24,000 BTU, abarcando tanto tecnologías Inverter como convencionales. El alcance funcional se restringió a un conjunto estructurado de diecinueve fallas comunes y recurrentes, asociadas a los principales componentes del sistema.

4.3 Comprensión de los Datos

En esta fase se llevó a cabo la recolección, evaluación y clasificación de la base de conocimiento destinada a alimentar el sistema RAG. La estrategia de búsqueda se enfocó exclusivamente en manuales de servicio oficiales y reportes técnicos de fabricantes reconocidos, descartando los manuales de usuario convencionales debido a su limitada profundidad en procesos de diagnóstico.

Con el objetivo de garantizar la calidad y relevancia de la base de conocimiento documental, se definió un protocolo de selección que exigía la presencia de secciones explícitas de resolución de problemas (troubleshooting), así como diagramas de flujo que establecieran relaciones claras entre síntomas, causas y acciones correctivas.

Adicionalmente, se excluyó documentación correspondiente a sistemas industriales, chillers y equipos portátiles, con el fin de evitar la introducción de información no pertinente que pudiera afectar la precisión del sistema.

Como criterio técnico adicional, se estableció la necesidad de legibilidad computacional de los documentos, requiriendo que estos se encontrarán en formato PDF nativo o que incluyeran capas de texto seleccionable. En consecuencia, se descartaron documentos complejos escaneados sin procesamiento de reconocimiento óptico de caracteres (OCR), debido a su incompatibilidad con los procesos de generación de representaciones vectoriales (embeddings).

Finalmente, los documentos seleccionados fueron sometidos a un esquema de evaluación cuantitativa en una escala de 0 a 100, priorizando aquellos que incluían códigos de error específicos, diagramas eléctricos detallados y tablas técnicas relevantes, considerados como elementos críticos para el proceso de diagnóstico.

4.4 Modelado de Datos

En esta fase se llevó a cabo el diseño, construcción y configuración del motor de la solución tecnológica, integrando los componentes de la arquitectura de RAG mediante el uso del framework LlamaIndex Core (versión 0.14.21) como orquestador principal.

La arquitectura definitiva del prototipo integra la interfaz web implementada con React (versión 19.2.4) y Vite (versión 8.0.1), el backend desarrollado con FastAPI (versión 0.115.12), el motor de ingesta, la base vectorial, la capa de persistencia local y los servicios externos de Gemini consumidos mediante Google GenAI SDK (versión 1.73.1). Dada la extensión del diagrama, se presenta en dos vistas complementarias que conservan la continuidad del flujo mediante las conexiones etiquetadas *BackgroundTasks* y *consulta RAG*. La primera vista, mostrada en la Figura 4.1, corresponde a las capas de interacción con el usuario (frontend SPA) y de orquestación en el backend, donde se observa el flujo de peticiones desde el navegador del técnico hacia la API y el servidor de archivos estáticos.




figure 4.1 Arquitectura Final del Sistema RAG para diagnóstico de HVAC. Vista 1: capas de usuario y backend. Fuente: [Elaboración propia]

La segunda vista, presentada en la Figura 4.2, detalla el motor de recuperación aumentada (ingesta y consulta RAG), la capa de persistencia local (SQLite, imágenes extraídas, manuales PDF e índice vectorial ChromaDB) y los servicios externos de Gemini en la nube. En conjunto, ambas vistas permi-

ten observar el flujo completo entre la consulta del técnico, la recuperación documental, la generación de respuestas fundamentadas y la entrega de evidencias visuales asociadas al manual consultado.




figure 4.2 Arquitectura Final del Sistema RAG para diagnóstico de HVAC. Vista 2: motor RAG, persistencia y servicios externos. Fuente: [Elaboración propia]

A diferencia de un enfoque estático, la configuración del sistema fue determinada a partir de un proceso iterativo de experimentación y validación empírica, sustentado en la ejecución de un plan de pruebas técnicas sobre el pipeline completo. Dichas pruebas abarcaron desde la ingestión de documentos hasta la generación final de respuestas, permitiendo identificar la interdependencia entre las decisiones de diseño en cada etapa del sistema .

Los resultados evidenciaron que las decisiones tomadas en fases previas, particularmente en la preparación de los datos, tienen efectos en cascada sobre la calidad de los embeddings y la precisión de la recuperación, validando así el enfoque iterativo propuesto por la metodología CRISP-DM .

En el componente de representación vectorial, se llevó a cabo un proceso de benchmarking comparando modelos de código abierto y soluciones propietarias. Los hallazgos demostraron que los modelos monolingües en inglés presentan un desempeño limitado en escenarios bilingües, debido a su incapacidad para mapear consultas en español con documentación técnica en inglés. En este contexto, el

modelo Gemini Embedding fue seleccionado por su capacidad multilingüe, alcanzando un desempeño significativamente superior en términos de recuperación semántica (Lee et al., 2025).

La información vectorizada fue almacenada utilizando ChromaDB (versión 0.6.3) como base de datos vectorial de código abierto caracterizada por un buen balance entre velocidad de recuperación, calidad de embeddings y rendimiento (Ammar et al., 2025), permitiendo la indexación eficiente de los documentos procesados.

En cuanto al componente de recuperación, se evaluaron diferentes configuraciones de búsqueda y síntesis de respuesta. Los resultados mostraron que las estrategias de síntesis jerárquica proporcionan mayor coherencia lógica en consultas de diagnóstico complejo, mientras que los modos de compactación resultan más eficientes para consultas directas relacionadas con códigos de error .

Finalmente, se integró el modelo generativo Gemini 1.5 Pro para la construcción de las respuestas (Reid et al., 2024), configurado con parámetros orientados a la precisión y reducción de variabilidad. La configuración final del sistema representa el resultado de un proceso de optimización basado en evidencia experimental, en el cual cada componente fue seleccionado en función de su impacto medible en la calidad de las respuestas generadas.

De forma paralela a la configuración del motor lógico del sistema RAG, se desarrolló el diseño inicial de la interfaz gráfica web destinada a la interacción con el usuario final. Este prototipo contempla dos componentes funcionales principales: un sistema de chat conversacional, mediante el cual el técnico formula consultas en lenguaje natural y recibe respuestas fundamentadas en la base vectorial, y un módulo de gestión documental que permite la carga y administración de los manuales de servicio que alimentan el corpus técnico del sistema. Las capturas de pantalla correspondientes al diseño preliminar de esta interfaz se documentan como evidencia en el Anexo C.

4.4.1 Implementación de Recuperación Multimodal Híbrida

Para abordar la recuperación multimodal, se evaluó el uso de índices multimodales nativos. Sin embargo, esta aproximación fue descartada con el objetivo de mantener un control arquitectónico estricto sobre la calidad de los recursos visuales procesados y optimizar los costos de inferencia. Los manuales técnicos de climatización presentan un alto nivel de ruido visual (logotipos, iconos decorativos) y contienen esquemas eléctricos o de tuberías contruidos mediante trazados vectoriales, los cuales no siempre son detectados como imágenes independientes.

Como solución arquitectónica superior, se diseñó e implementó un módulo de extracción estática basado en la biblioteca PyMuPDF (versión 1.27.2.3). Este componente aplica umbrales de filtrado para capturar únicamente diagramas de valor técnico y cuenta con la capacidad de renderizar páginas com-

pletas para asegurar la preservación de diagramas vectoriales. Posteriormente, en lugar de sobrecargar el motor vectorial o el modelo de lenguaje con el procesamiento de imágenes en tiempo real, los recursos visuales se alojan en un servidor de archivos estáticos local. Sus rutas de acceso se inyectan como metadatos estructurados dentro de los nodos de texto de ChromaDB.

Esta estrategia híbrida garantiza que la interfaz de usuario reciba las referencias visuales directamente desde el servidor estático, evitando procesar miles de tokens de imagen en el LLM durante cada consulta, lo que maximiza la eficiencia, reduce la latencia y mantiene la estabilidad operativa del sistema.

Adicionalmente, para mejorar la recuperación de páginas cuyo valor técnico reside principalmente en esquemas o ilustraciones, se incorporó una etapa de descripción visual durante la ingesta. Las páginas con rasgos visuales relevantes pueden ser procesadas por un modelo con capacidad de visión para producir una descripción textual del contenido gráfico. Dicha descripción se integra al corpus indexado, permitiendo que preguntas formuladas en lenguaje natural recuperen páginas visualmente pertinentes aunque el diagrama original no sea directamente interpretable por el modelo de embeddings.

4.4.2 Estrategia de Ingesta Escalable

La primera versión del flujo de ingesta fue diseñada para operar bajo las restricciones de la capa gratuita de la API de Gemini. En ese entorno, el principal cuello de botella no estaba en el almacenamiento vectorial ni en la lógica de fragmentación documental, sino en los límites de cuota del servicio de embeddings. Para evitar bloqueos por exceso de solicitudes, el sistema debía procesar lotes reducidos de cinco fragmentos e introducir pausas forzadas de doce segundos entre llamadas sucesivas. Esta configuración resultaba funcional para pruebas iniciales, pero producía tiempos de indexación poco eficientes, con demoras cercanas a ocho minutos por manual técnico extenso.

Posteriormente, el sistema fue adaptado para operar con una API Tier 1 pospago. Esta migración permitió eliminar las pausas artificiales asociadas al entorno gratuito y aumentar el tamaño de lote hasta cien fragmentos por petición. El cambio no modificó la estrategia conceptual del modelo RAG: se mantuvieron los criterios de fragmentación, el modelo de embeddings seleccionado y ChromaDB como repositorio vectorial persistente. La mejora se concentró en el rendimiento operativo de la ingesta, reduciendo significativamente el tiempo de indexación y ubicando el procesamiento de manuales extensos en poco más de un minuto, dependiendo de la cantidad de páginas que requirieran análisis visual.

Desde el punto de vista arquitectónico, esta decisión separa dos preocupaciones distintas. Por un lado, el diseño lógico del sistema define cómo se representan, almacenan y recuperan los documentos técnicos. Por otro lado, la configuración de cuota determina cuántos fragmentos pueden procesarse

por unidad de tiempo. Al migrar hacia un entorno Tier 1, el prototipo demuestra que el pipeline puede escalar sin modificar su estructura semántica ni comprometer la calidad de recuperación.

No obstante, se mantuvo la posibilidad de retornar a una configuración compatible con la capa gratuita. Esta consideración es relevante porque el uso de una API pospago depende de recursos asumidos por el equipo de desarrollo, mientras que futuras iteraciones académicas podrían optar por continuar con una clave gratuita o utilizar una clave de pago propia. Por tanto, el diseño final contempla dos perfiles operativos: uno conservador, orientado a estabilidad bajo restricciones de cuota, y otro optimizado con Tier 1 pospago, empleado durante las pruebas técnicas, la preparación del prototipo y la evaluación con usuarios finales.

Tanto el desarrollo iterativo del *pipeline* como las cinco sesiones de evaluación con usuarios finales del Capítulo 5 se ejecutaron con el perfil Tier 1 pospago. Las pruebas iniciales bajo capa gratuita sirvieron únicamente para validar la viabilidad del flujo de ingesta y cuantificar el impacto de las restricciones de cuota antes de la migración definitiva a Tier 1.

4.4.3 Gestión de Estado y Persistencia

Otra decisión relevante del modelado fue la incorporación de persistencia conversacional. En un sistema de diagnóstico técnico, las interacciones no siempre son consultas aisladas; el usuario puede formular preguntas de seguimiento, complementar síntomas, corregir mediciones o solicitar una explicación adicional a partir de una respuesta previa. Si cada consulta se procesara como una transacción independiente, el asistente perdería continuidad contextual y la experiencia de diagnóstico se volvería fragmentada.

Para resolver esta limitación de memoria, se integró una base de datos relacional interna SQLite (versión 3.51.3) llamada `conversation.db`, administrada mediante SQLAlchemy (versión 2.0.41). Esta base permite almacenar conversaciones, mensajes del usuario, respuestas del asistente, marcas temporales y referencias documentales utilizadas durante la generación de la respuesta. Con ello, el historial de chat deja de depender exclusivamente del estado temporal de la interfaz y pasa a formar parte de una capa persistente administrada por el backend.

El flujo conversacional resultante permite que una consulta nueva se asocie a una conversación existente o que se cree una conversación independiente cuando el usuario inicia un diagnóstico nuevo. Antes de generar una respuesta, el sistema recupera el historial reciente de la conversación y lo incorpora como contexto auxiliar. Esta memoria no reemplaza la recuperación documental ni autoriza al modelo a responder sin evidencia; su función es mantener continuidad semántica entre turnos, mientras que la fundamentación técnica sigue dependiendo de los fragmentos recuperados desde la base vectorial.

La misma capa de persistencia permitió implementar aislamiento de sesiones mediante perfiles de usuario predefinidos. Para la fase de pruebas de aceptación con técnicos, cada perfil cuenta con un historial independiente, lo cual evita que las consultas, respuestas y contextos de un participante se mezclen con los de otro. Este aislamiento es fundamental para evaluar el prototipo en condiciones controladas, ya que permite observar el uso individual de la herramienta, conservar trazabilidad de cada sesión y reducir interferencias entre pruebas.

Aunque estos perfiles no constituyen un sistema de autenticación productivo, son suficientes para el alcance del prototipo académico. La solución permite validar persistencia, continuidad conversacional y separación de contextos sin introducir complejidad innecesaria, manteniendo una arquitectura coherente con un Producto Mínimo Viable orientado a evaluación técnica.

CAPÍTULO 5. PRESENTACIÓN, ANÁLISIS E INTERPRETACIÓN DE RESULTADOS

Este capítulo expone los resultados obtenidos durante la fase de evaluación del prototipo del asistente de diagnóstico basado en Generación Aumentada por Recuperación (RAG) para aires acondicionados tipo Split. La evaluación se estructuró en dos dimensiones complementarias: la verificación funcional de los casos de uso definidos en el Plan de Pruebas Técnicas, y la validación de la experiencia con cinco usuarios finales del dominio HVAC mediante un instrumento de evaluación estructurado¹. Se complementa el análisis con la documentación crítica de las limitaciones operativas y los casos borde identificados, presentados como hallazgos de alto valor ingenieril que delimitan el alcance actual del sistema y orientan el trabajo futuro.

5.1 Resultados de la Evaluación con Usuarios Finales

Se realizaron cinco sesiones de evaluación entre el 26 de mayo y el 2 de junio de 2026, con participantes del sector técnico de climatización cuya experiencia oscila entre menos de un año y cinco años en la profesión. Los técnicos evaluaron el prototipo utilizando manuales de servicio reales de tres fabricantes distintos: Daikin (tres sesiones, modelos FTXR-T Series, FTXS-L/FDXS-L Series y FTX18-24UVJU), Mabe (Tundra Inverter Series) y Toshiba (RAS-E2KVG Series). La heterogeneidad de los manuales empleados permitió verificar que el comportamiento del sistema no se limita a una sola marca o modelo, sino que responde de manera consistente ante documentos técnicos de distinta procedencia y estructura interna.

5.1.1 Métricas de Usabilidad e Integración del Flujo de Trabajo

El 100 % de los participantes (5 de 5) completó la evaluación de principio a fin, logró cargar el manual de servicio en el prototipo de forma exitosa y confirmó que la indexación del documento finalizó correctamente. En cuanto al tiempo de espera durante la fase de carga e indexación, los cinco usuarios respondieron *Muy de acuerdo* ante el ítem “*El tiempo de espera para poder consultar el manual fue aceptable*”, lo que equivale a una tasa de aceptación unánime en esta métrica. Esta unanimidad es un indicador relevante dado que las sesiones operaron con cuota Tier 1 pospago de Google AI Studio (véase la Sección 4.4.2), perfil en el que la indexación de un manual extenso se completó en poco más de un minuto; la totalidad de los evaluadores calificó esa espera como aceptable.

Asimismo, los cinco participantes respondieron *Muy de acuerdo* ante el ítem “*El prototipo funcionó sin errores técnicos visibles durante la prueba*”, confirmando la estabilidad operativa del sistema a lo largo de todas las sesiones de evaluación. La coincidencia de ambas métricas con el valor máximo de la escala sugiere que la interfaz de usuario logró abstraer adecuadamente los procesos internos del *pipeline* RAG, presentando al técnico una experiencia fluida sin exposición a errores de bajo nivel.

¹Los resultados gráficos en bruto de la herramienta de evaluación pueden consultarse en línea en: <https://tinyurl.com/2vasbczd>

En las métricas de diseño de la interfaz, cuatro de cinco usuarios indicaron *Muy de acuerdo* ante la facilidad para subir el manual PDF y ante la correcta identificación visual del documento cargado; un usuario respondió *Ligeramente de acuerdo* en ambos ítems. La métrica sobre la claridad del flujo desde la carga hasta el chat presentó mayor variabilidad: tres usuarios respondieron *Ligeramente de acuerdo* y dos *Muy de acuerdo*, lo que señala una oportunidad de mejora en la guía visual al usuario durante la transición entre la etapa de carga y la interfaz conversacional.

5.1.2 Métricas de Calidad de las Respuestas

Los resultados en las dimensiones de calidad de las respuestas presentan un panorama generalmente favorable, con excepción de un caso crítico que se analiza en la sección siguiente. A continuación se presentan las distribuciones de respuesta para los principales ítems del instrumento de evaluación.

Tabla 5.1 Distribución de respuestas Likert del instrumento de evaluación del prototipo

Ítem evaluado	MDA	LDA	N	LDE	MDE
El tiempo de espera para consultar el manual fue aceptable	5	0	0	0	0
El prototipo funcionó sin errores técnicos visibles	5	0	0	0	0
El proceso para subir el manual PDF fue fácil de entender	4	1	0	0	0
El asistente entendió correctamente las preguntas realizadas	4	0	0	0	1
Las respuestas fueron claras y fáciles de comprender	4	1	0	0	0
La información técnica fue suficientemente precisa para tomar decisiones de mantenimiento	4	1	0	0	0
El asistente mantuvo el contexto entre una pregunta y otra	4	1	0	0	0
El lenguaje utilizado fue adecuado para el perfil del usuario	4	1	0	0	0
Las respuestas fueron útiles para diagnosticar problemas HVAC	3	1	1	0	0
Las fuentes mostradas fueron relevantes para la respuesta	3	1	1	0	0
Las respuestas parecieron estar basadas en el manual cargado	3	1	0	0	1

Tabla 5.1 Distribución de respuestas Likert del instrumento de evaluación del prototipo (continuación)

Ítem evaluado	MDA	LDA	N	LDE	MDE
El asistente evitó respuestas genéricas cuando el manual tenía información específica	3	1	1	0	0
El asistente diferenció entre recomendaciones para usuario final y tareas que requieren técnico especializado	1	0	3	1	0
Las recomendaciones incluyeron advertencias de seguridad cuando eran necesarias	1	1	2	1	0

Nota: MDA = Muy de acuerdo; LDA = Ligeramente de acuerdo; N = Neutral; LDE = Ligeramente en desacuerdo; MDE = Muy en desacuerdo.

Fuente: Elaboración propia (2026), basada en instrumento de evaluación aplicado a cinco técnicos HVAC.

Como se observa en la Tabla 5.1, la claridad de las respuestas generadas fue calificada como *Muy de acuerdo* por cuatro de cinco usuarios, mientras que la utilidad para diagnosticar o comprender problemas HVAC obtuvo tres respuestas *Muy de acuerdo*, una *Ligeramente de acuerdo* y una *Neutral*. Esta distribución refleja que los usuarios con mayor experiencia técnica esperaban, en algunos casos, respuestas con mayor profundidad procedimental o mayor densidad de pasos verificables. La métrica de precisión técnica para apoyar decisiones de mantenimiento obtuvo cuatro respuestas *Muy de acuerdo* y una *Ligeramente de acuerdo*, reforzando la utilidad práctica del sistema en el contexto del operario de campo.




figure 5.1 Distribución de respuestas por dimensión de calidad. Fuente: [Elaboración propia]

La métrica sobre fuentes relevantes mostradas al usuario obtuvo tres respuestas *Muy de acuerdo*, una *Ligeramente de acuerdo* y una *Neutral*. Esto es coherente con la observación registrada por el participante que evaluó el manual de Toshiba, quien anotó que en una de las consultas comunes el sistema no citó fuentes del manual. Este comportamiento es atribuible a las diferencias en el modo de síntesis empleado según el tipo de consulta: las búsquedas directas priorizan la eficiencia reduciendo el número de llamadas a la API, lo que ocasionalmente omite la referencia explícita al fragmento

fuentes.

5.1.3 Análisis Crítico: Polarización en la Comprensión de Consultas

El ítem con mayor dispersión de respuestas fue “*El asistente entendió correctamente las preguntas realizadas*”, donde cuatro usuarios respondieron *Muy de acuerdo* y un usuario respondió *Muy en desacuerdo*, tal como se ilustra en la Figura 5.2.

Este único caso de disconformidad severa corresponde a la sesión en la que se evaluó el manual Mabe Tundra Inverter Series. El análisis de las preguntas formuladas por dicho participante revela que las consultas empleadas fueron altamente coloquiales y escuetamente formuladas: “*La unidad evaporada se congela*”, sin especificación de síntomas adicionales, condiciones ambientales ni historial previo del equipo. Este tipo de consulta omite el contexto técnico mínimo necesario para que el recuperador identifique fragmentos diagnósticos de alta relevancia: una frase breve sin vocabulario técnico especializado genera vectores de consulta que no se alinean con precisión a los fragmentos del manual, produciéndose respuestas más genéricas que el usuario percibe como falta de comprensión. Este patrón es consistente con los resultados de las pruebas funcionales de nivel avanzado, donde consultas coloquiales similares produjeron los puntajes de similitud más bajos de toda la batería de recuperación, limitando a su vez la calidad de la síntesis generada por el modelo.




figure 5.2 Distribución de respuestas para el ítem “El asistente entendió correctamente las preguntas realizadas”. Fuente: [Elaboración propia]

Adicionalmente, el mismo participante indicó *Muy en desacuerdo* ante el ítem “*Las respuestas parecieron estar basadas en el manual cargado*”, lo que sugiere que cuando el sistema produce una respuesta genérica ante una consulta imprecisa, el usuario no percibe la trazabilidad con el documento fuente, aunque técnicamente el sistema sí recuperó fragmentos del manual. Este hallazgo señala la necesidad futura de implementar mecanismos de retroalimentación iterativa que orienten al usuario hacia formulaciones más estructuradas cuando la consulta inicial resulta demasiado ambigua para una recuperación semántica precisa.

5.1.4 Métricas de Seguridad y Diferenciación de Perfil Técnico

Las métricas de seguridad presentaron la mayor dispersión del instrumento. El ítem “*El asistente diferenció entre recomendaciones para usuario final y tareas que requieren técnico especializado*” obtuvo tres respuestas *Neutral*, una *Muy de acuerdo* y una *Ligeramente en desacuerdo*. De manera similar, el ítem sobre la inclusión de advertencias de seguridad obtuvo una *Muy de acuerdo*, una *Ligeramente de acuerdo*, dos *Neutral* y una *Ligeramente en desacuerdo*. Esta dispersión indica que el comportamiento del prototipo en materia de escalación de responsabilidad técnica y comunicación de riesgos no es consistente entre sesiones, constituyendo un área de mejora prioritaria para versiones futuras del sistema, independientemente de los resultados favorables en las dimensiones de usabilidad y calidad de respuestas.




figure 5.3 Distribución de respuestas en métricas de seguridad y diferenciación de perfil técnico. Fuente: [Elaboración propia]

5.2 Casos de Uso y Verificación Funcional

Durante las cinco sesiones de evaluación, los participantes formularon un total de quince preguntas específicas y diez preguntas de categoría común, cubriendo escenarios de diagnóstico representativos del trabajo cotidiano del técnico en campo. El análisis cualitativo de estas interacciones permite identificar patrones claros de comportamiento del sistema ante distintos tipos de consulta, así como el impacto real de la herramienta en la eficiencia del proceso diagnóstico.

5.2.1 Desempeño ante Preguntas Comunes

Las preguntas comunes incluyeron consultas sobre síntomas frecuentes en equipos tipo Split, tales como el congelamiento de la unidad evaporadora, ruidos durante el arranque del compresor y procedimientos de mantenimiento preventivo. Ante estos escenarios, el sistema demostró capacidad efectiva de mapeo semántico: las respuestas generadas obtuvieron calificaciones de *Alto* y *Muy Alto* en claridad, alineación con el manual y utilidad para resolver la duda, con trazabilidad confirmada de fuentes en la mayoría de los casos. El sistema recuperó fragmentos específicos de los manuales cargados y

los sintetizó en respuestas coherentes, reduciendo el tiempo de búsqueda manual que en condiciones normales implicaría navegar entre decenas o cientos de páginas de documentación técnica.

No obstante, en al menos una sesión se documentó que el asistente no citó fuentes del manual en una de las preguntas comunes, observación registrada directamente por el participante que evaluó el equipo Toshiba. Este comportamiento es atribuible al modo de síntesis empleado para consultas de bajo nivel de complejidad, que optimiza la eficiencia de las llamadas a la API priorizando la concisión sobre la trazabilidad explícita de las fuentes. Este hallazgo refuerza la recomendación de aplicar de forma sistemática el modo de síntesis orientado a la completitud para todas las consultas que requieran evidencia documental explícita.

5.2.2 Desempeño ante Preguntas Específicas

Las preguntas específicas abarcaron tres niveles de complejidad diagnóstica. En el nivel básico, los usuarios consultaron códigos de error documentados directamente en los manuales cargados: *“La placa muestra un error llamado E6, ¿qué puedo hacer?”* (manual Daikin), *“Me tira el código 1C en el equipo, ¿qué falla es y qué sensor tengo que desconectar en la tarjeta interior para probar?”* (manual Toshiba) y *“El equipo se enfrentó a una alteración súbita de energía eléctrica y muestra un código en el display”* (manual Daikin FTX). En los tres casos, las respuestas recibieron calificaciones de *Muy Alto* en claridad y alineación con el manual, con trazabilidad de fuentes confirmada, resultado consistente con el comportamiento esperado del sistema ante consultas directas de código de error.

En el nivel de complejidad media, el sistema respondió satisfactoriamente ante consultas de diagnóstico diferencial como *“La válvula de succión no está funcionando, ¿qué puedo hacer?”*, *“Cuando empieza a trabajar el compresor, hay un ruido extraño, ¿qué podría causarlo?”* y *“Hace un tiempo que el aire arroja lo que parecieran ser trozos de hielo o escarcha y le cuesta enfriar”*. Estas consultas requieren que el sistema sintetice información de varias secciones del manual (síntomas, causas probables y procedimientos de verificación), capacidad que el prototipo demostró de manera consistente al relacionar el síntoma descrito con las fichas diagnósticas correspondientes del documento fuente.

En el nivel avanzado, el participante con mayor experiencia (entre 3 y 5 años) formuló consultas que requerían explícitamente la interpretación de diagramas y esquemas del manual: *“¿Podría explicar a detalle las funciones principales de este tipo de aires y mostrar diagramas relevantes?”* y *“En base al manual, explica y muestra un diagrama de cómo se quita correctamente la caja eléctrica del evaporador”*. En estos casos, el sistema proporcionó descripciones textuales correctas de los procedimientos, pero sin capacidad de identificar, referenciar ni describir el contenido visual específico de los diagramas embebidos en el manual, limitante que se detalla en la Sección 5.3.3.

5.2.3 Impacto en la Productividad del Técnico

Los resultados consolidados de las quince preguntas específicas muestran que en 14 de 15 casos (93 %) las respuestas fueron calificadas como correctas y completas por los evaluadores. El sistema referenciando fuentes obtuvo una tasa de citación explícita del manual en 13 de 15 preguntas específicas (87 %), con dos casos de citación parcial y ningún caso de ausencia total de fuente en este bloque. Estas métricas sustentan la conclusión de que el prototipo reduce significativamente el esfuerzo de búsqueda manual: en lugar de navegar entre 100 y 200 páginas de documentación técnica, el técnico recibe una respuesta sintetizada con trazabilidad al manual fuente en un tiempo de entre 2 y 10 segundos según la complejidad de la consulta. Para un operario en campo que debe tomar decisiones con el equipo detenido y el cliente presente, esta reducción del tiempo de diagnóstico representa una ventaja operativa directa.

5.3 Limitaciones del Sistema y Casos Borde

La evaluación del prototipo permitió identificar tres limitaciones operativas de relevancia para el trabajo futuro. Estas se presentan no como deficiencias del diseño, sino como hallazgos ingenieriles documentados que delimitan el alcance actual del sistema y justifican líneas específicas de investigación futura.

5.3.1 Límite de Cuota y Degradación ante Carga Masiva

El sistema consumió la API de Google AI Studio bajo cuota Tier 1 pospago tanto durante el desarrollo como en las cinco sesiones de evaluación con usuarios finales (Sección 4.4.2). En ese perfil, la indexación de un manual extenso se completó en poco más de un minuto y el tiempo de espera fue calificado como aceptable por la totalidad de los evaluadores.

No obstante, las pruebas iniciales del *pipeline* bajo la capa gratuita evidenciaron una limitación estructural: los límites de peticiones por minuto y de tokens por minuto obligan a procesar lotes reducidos con pausas entre solicitudes, extendiendo la indexación a aproximadamente siete u ocho minutos por manual y generando errores de cuota excedida (HTTP 429) ante cargas concurrentes. Aunque el diseño conserva compatibilidad con ese perfil conservador, su uso en producción degradaría la experiencia del técnico o provocaría fallos sin mensaje comprensible para el usuario final.

Esta restricción no constituye una deficiencia del *pipeline* RAG en sí mismo, pero sí una dependencia operativa: mantener tiempos de indexación aceptables y soportar uso concurrente exige cuota de pago ampliada o, alternativamente, modelos de código abierto desplegados localmente.

5.3.2 Alucinación por Transferencia de Dominio

El hallazgo de mayor riesgo operativo identificado durante las pruebas corresponde al caso borde documentado al consultar: “¿Cómo reparo la tarjeta inversora de un equipo VRF de 10 toneladas?”. Ante esta consulta, el sistema generó un procedimiento técnico detallado y aparentemente confiable, incluyendo la verificación de arneses, la medición del voltaje en el condensador electrolítico (320 VDC), la inspección del puente de diodos y el uso de un analizador de inversor específico, sin emitir ninguna advertencia sobre el hecho de que el equipo VRF de 10 toneladas consultado no está documentado en ninguna página del manual cargado.

Este comportamiento constituye una *alucinación por transferencia de dominio*: el recuperador identificó nodos semánticamente relacionados con el término “tarjeta inversora”, correspondientes al equipo Split residencial documentado en el manual fuente, y el modelo generativo los sintetizó como una respuesta confiada sin verificar si el tipo de equipo consultado se encontraba dentro del alcance del documento. La evaluación manual de esta respuesta obtuvo la calificación más baja de toda la batería de pruebas funcionales, siendo el único caso con alucinación confirmada. El riesgo operativo real es significativo: un técnico de campo podría aplicar, de buena fe, procedimientos diseñados para un equipo Split residencial de baja capacidad a un sistema VRF de alta capacidad industrial, con potencial daño al equipo, pérdida económica para el cliente o riesgo para la integridad física del técnico. Este hallazgo justifica la implementación futura de mecanismos de *guardrails* de seguridad: clasificadores previos a la generación que verifiquen si el tipo de equipo consultado está explícitamente cubierto por el manual fuente antes de producir una respuesta.

5.3.3 Limitante Multimodal

Durante la sesión de evaluación con el manual Daikin FTXS-L/FDXS-L Series, el participante con mayor experiencia técnica formuló consultas que requerían explícitamente la interpretación de diagramas eléctricos y de instalación. En ambos casos, el sistema proporcionó descripciones textuales de los componentes sin poder identificar, referenciar ni describir el contenido visual específico de los diagramas embebidos en el manual. Esta limitante fue identificada y señalada durante la reunión de seguimiento del trabajo de graduación con el director del proyecto.

El *pipeline* RAG del prototipo opera sobre representaciones puramente textuales extraídas del PDF: las páginas de diagramas eléctricos son procesadas como texto plano con referencias numéricas a componentes que carecen del contexto visual asociado. El modelo generativo empleado en el entorno del prototipo carece de capacidad multimodal nativa para interpretar imágenes embebidas en los documentos indexados. Por consiguiente, ante cualquier consulta que requiera razonamiento sobre esquemas eléctricos, diagramas de tuberías, diagramas de flujo de diagnóstico visual o tablas de valores gráficas, el sistema produce respuestas genéricas basadas únicamente en las descripciones

textuales disponibles, que en los manuales de servicio suelen ser insuficientes para guiar al técnico en procedimientos que requieren el apoyo visual del diagrama original.

Esta limitante es inherente a la arquitectura actual del prototipo y no puede resolverse mediante ajustes de parámetros del sistema: su resolución requiere la integración de un modelo generativo con capacidad de procesamiento multimodal nativa, tal como se detalla en las recomendaciones del Capítulo 6.

CAPÍTULO 6. CONCLUSIONES Y RECOMENDACIONES

6.1 Conclusiones

Se diseñó e implementó con éxito el *pipeline* de recuperación semántica que constituye el núcleo del sistema de Generación Aumentada por Recuperación (RAG), definiendo las estrategias de ingesta y particionado (*chunking*) del corpus documental técnico. La validación empírica demostró que la ingesta de PDF nativo preserva la integridad semántica de las fichas diagnósticas de forma marcadamente superior al texto plano pre-extraído, decisión de ingeniería de datos que resultó determinante para la calidad de la recuperación posterior. Sobre esta base se construyó la base de datos vectorial del sistema mediante ChromaDB, seleccionando por *benchmarking* el modelo de *embeddings* multilingüe Gemini Embedding 001, que alcanzó una tasa de recuperación del 80 % y superó en 60 puntos porcentuales a los modelos monolingües de código abierto evaluados, incapaces de mapear las consultas en español contra el corpus técnico en inglés. Finalmente, se configuró la estrategia de generación aumentada y los *prompts* de sistema orientados a acotar el contexto de recuperación, acoplando el modelo generativo al recuperador para mitigar las alucinaciones por transferencia de dominio de los modelos de lenguaje.

A partir de manuales de servicio oficiales de múltiples fabricantes se construyó el repositorio documental curado que alimenta el sistema, y sobre él se integró un modelo de lenguaje que genera recomendaciones diagnósticas fundamentadas *exclusivamente* en los fragmentos recuperados de dichos documentos, reduciendo la ambigüedad característica de los modelos de lenguaje generalistas. En las pruebas funcionales, el sistema alcanzó una tasa de citación explícita de la fuente documental en el 87 % de las preguntas específicas evaluadas. En el instrumento de evaluación, cuatro de cinco usuarios (80 %) manifestaron acuerdo respecto a que las respuestas parecieron estar basadas en el manual cargado; el participante restante registró desacuerdo total, en coherencia con las consultas excesivamente coloquiales documentadas en la Sección 5.1.3. Esta capacidad de trazabilidad documental distingue al prototipo de las herramientas genéricas identificadas en el planteamiento del problema, las cuales carecen del contexto técnico específico del fabricante y generan respuestas redundantes sin referencia a la documentación de origen.

La evaluación del prototipo con cinco técnicos activos del dominio HVAC, mediante el instrumento diseñado específicamente para el proyecto, validó empíricamente que el sistema reduce de forma significativa el esfuerzo de búsqueda manual. El 100 % de los evaluadores calificó el tiempo de espera como aceptable y confirmó la ausencia de errores técnicos visibles durante las sesiones de prueba. El 93 % de las preguntas específicas fue calificado como correcto y completo por los propios técnicos evaluadores. Estas métricas demuestran que el prototipo cumple el objetivo de reducir el tiempo de diagnóstico en campo: el asistente entrega respuestas sintetizadas con trazabilidad al documento fuente en tiempos de entre dos y diez segundos según la complejidad de la consulta, en contraste con los

uno a cinco minutos promedio por búsqueda manual reportados por los mismos profesionales durante la fase de comprensión del problema. Se concluye que el sistema constituye una herramienta de apoyo técnico funcional, validada positivamente por sus usuarios finales en las dimensiones de utilidad, claridad, precisión técnica y mantenimiento del contexto conversacional.

6.2 Recomendaciones

Con base en las limitaciones operativas y los casos borde documentados en el Capítulo 5, se plantean las siguientes líneas de trabajo futuro orientadas a ampliar las capacidades del sistema y mitigar los riesgos identificados durante la evaluación.

6.2.1 Integración de Modelos de Lenguaje Multimodales Nativos

La limitante multimodal identificada en la Sección 5.3.3 constituye la brecha funcional más relevante del prototipo actual. El sistema responde con descripciones textuales genéricas ante consultas que requieren razonamiento sobre diagramas eléctricos, esquemas de tuberías o tablas de valores gráficas embebidos en los manuales de servicio, precisamente porque el *pipeline* RAG opera exclusivamente sobre representaciones textuales extraídas del PDF. Esta restricción impide que el técnico obtenga orientación visual directa en procedimientos que, en la práctica, dependen de la interpretación de diagramas.

Se recomienda que en investigaciones futuras se integre un modelo de lenguaje con capacidad multimodal nativa que permita al sistema procesar directamente las imágenes embebidas en los documentos técnicos. Esta integración habilitaría al asistente para describir con precisión el contenido de diagramas eléctricos, identificar componentes específicos en esquemas de instalación y razonar sobre representaciones visuales de procedimientos de diagnóstico, superando la dependencia actual de las descripciones textuales que los manuales de servicio incluyen de forma parcial e insuficiente. Arquitecturas recientes de recuperación aumentada basadas en visión, que incorporan páginas completas de documentos como imágenes en el proceso de recuperación, han demostrado mejoras de entre 20 y 40 % en calidad de recuperación y respuesta frente a sistemas de solo texto sobre documentos con contenido visual (Tanaka et al., 2025), con resultados igualmente favorables en dominios de ingeniería que emplean manuales técnicos con diagramas de flujo (Soman et al., 2025).

6.2.2 Implementación de Preguntas de Retroalimentación Interactiva

El análisis crítico de la Sección 5.1.3 documentó que consultas excesivamente coloquiales o genéricas, como “*La unidad evaporada se congela*”, producen vectores de consulta de baja precisión semántica que no se alinean con las fichas diagnósticas de los manuales, generando respuestas que el usuario percibe como incomprensión del asistente. Este comportamiento, aunque técnicamente explicable por

la imprecisión del lenguaje de entrada, representa una experiencia deficiente para el técnico en campo.

Se recomienda implementar un mecanismo de retroalimentación interactiva que detecte consultas de baja densidad técnica o alta ambigüedad y, en lugar de generar una respuesta genérica, formule preguntas aclaratorias al usuario antes de iniciar la recuperación semántica. Por ejemplo, ante la consulta anterior, el sistema podría solicitar información sobre el modelo del equipo, la presencia de códigos de error activos o las condiciones ambientales. La efectividad de este enfoque está respaldada por evidencia empírica: en sistemas de búsqueda de dominio abierto, una sola pregunta aclaratoria bien formulada puede producir mejoras superiores al 170 % en la precisión del resultado recuperado (Aliannejadi et al., 2019); de manera complementaria, arquitecturas que aumentan modelos de lenguaje con la capacidad explícita de generar preguntas de clarificación previas a la recuperación reportan ganancias relativas de entre 17 y 39 % frente a sistemas sin esta capacidad (Chi et al., 2024). Integrar esta lógica en el asistente reduciría la tasa de respuestas genéricas y aumentaría la precisión diagnóstica sin requerir que el técnico reformule manualmente su consulta.

6.2.3 Desarrollo de *Guardrails* de Seguridad para Prevenir Alucinaciones por Transferencia de Dominio

El caso borde documentado en la Sección 5.3.2 constituye el hallazgo de mayor riesgo operativo del proyecto: ante la consulta sobre un equipo VRF de 10 toneladas, fuera del dominio del manual cargado, el sistema generó un procedimiento técnico detallado y confiado, transfiriendo información del equipo Split residencial sin advertencia alguna. Esta *alucinación por transferencia de dominio* puede inducir al técnico a aplicar procedimientos incorrectos en sistemas incompatibles, con potencial daño al equipo o riesgo para la integridad del profesional.

Se recomienda la implementación de *guardrails* de seguridad como capa de validación previa a la generación de respuestas. Estos mecanismos deberían verificar, a partir de la consulta del usuario, si el tipo de equipo mencionado está explícitamente cubierto por el manual fuente indexado, y bloquear o redireccionar la consulta antes de que el modelo generativo la procese en caso de detectar una discrepancia de dominio. El fundamento teórico de este enfoque descansa en que la recuperación aumentada reduce significativamente las alucinaciones en sistemas conversacionales al anclar las respuestas en evidencia documental verificable (Shuster et al., 2021). Investigaciones recientes en entornos de seguridad crítica como la farmacovigilancia, dominio en el que un error de clasificación tiene consecuencias físicas directas comparables a las del diagnóstico técnico de equipos, han validado que los *guardrails* duros, que bloquean tipos de error específicos, y los *guardrails* blandos, que señalan segmentos inciertos para revisión humana, pueden diseñarse sin degradar el rendimiento en consultas válidas dentro del dominio (Hakim et al., 2025). Esta recomendación es prioritaria para cualquier despliegue del sistema en un entorno productivo real, donde el costo de una respuesta incorrecta supera con creces el costo de una respuesta conservadora.

REFERENCIAS

- Aliannejadi, M., Zamani, H., Crestani, F., & Croft, W. B. (2019). Asking Clarifying Questions in Open-Domain Information-Seeking Conversations. *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 475-484. <https://doi.org/10.1145/3331184.3331265>
- Ammar, A., Koubaa, A., Nacar, O., & Boulila, W. (2025). Optimizing Retrieval-Augmented Generation: Analysis of Hyperparameter Impact on Performance and Efficiency. *ArXiv*, *abs/2505.08445*. <https://doi.org/10.48550/arxiv.2505.08445>
- Anh-Hoang, D., Tran, V., & Nguyen, L. (2025). Survey and analysis of hallucinations in large language models: attribution to prompting strategies or model behavior. *Frontiers in Artificial Intelligence*, 8. <https://doi.org/10.3389/frai.2025.1622292>
- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., et al. (2020). Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems*, 33, 1877-1901. <https://papers.nips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-Step Data Mining Guide* (inf. téc.). SPSS Inc.
- Chi, Y., Lin, J., Lin, K., & Klein, D. (2024). CLARINET: Augmenting Language Models to Ask Clarification Questions for Retrieval. *ArXiv*, *abs/2405.15784*. <https://doi.org/10.48550/arxiv.2405.15784>
- Hakim, J. B., Painter, J. L., Ramcharran, D., Kara, V., Powell, G., Sobczak, P., Sato, C., Bate, A., & Beam, A. (2025). The need for guardrails with large language models in pharmacovigilance and other medical safety critical settings. *Scientific Reports*, 15. <https://doi.org/10.1038/s41598-025-09138-0>
- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, 55(12). <https://arxiv.org/abs/2304.00361>
- Jurafsky, D., & Martin, J. H. (2023). *Speech and Language Processing* (3.^a ed.) [Draft]. Stanford University. <https://web.stanford.edu/~jurafsky/slp3/>

Krütli, D., & Hanne, T. (2025). Augmenting LLMs to Securely Retrieve Information for Construction and Facility Management. *Information*, 16, 76. <https://doi.org/10.3390/info16020076>

Lee, J., Chen, F., Dua, S., Cer, D., Shanbhogue, M., et al. (2025). Gemini Embedding: Generalizable Embeddings from Gemini. *ArXiv*, *abs/2503.07891*. <https://doi.org/10.48550/arxiv.2503.07891>

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems*, 33. <https://arxiv.org/abs/2005.11401>

LlamaIndex. (2024). *LlamaIndex Documentation*. Consultado el 8 de abril de 2026, desde <https://docs.llamaindex.ai>

Mariscal, G., Marbán, Ó., & Fernández, C. (2010). A survey of data mining and knowledge discovery process models and methodologies. *The Knowledge Engineering Review*.

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient Estimation of Word Representations in Vector Space. *arXiv preprint arXiv:1301.3781*. <https://arxiv.org/abs/1301.3781>

Reid, M., Savinov, N., Teplyashin, D., Lepikhin, D., Lillicrap, T., et al. (2024). Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context. *ArXiv*, *abs/2403.05530*.

Shearer, C. (2000). The CRISP-DM model: The new blueprint for data mining. *Journal of Data Warehousing*.

Shuster, K., Poff, S., Chen, M., Kiela, D., & Weston, J. (2021). Retrieval Augmentation Reduces Hallucination in Conversation. *Findings of the Association for Computational Linguistics: EMNLP 2021*, 3784-3803. <https://doi.org/10.18653/v1/2021.findings-emnlp.320>

Soman, S., Ranjani, H. G., Roychowdhury, S., Sastry, V. D. S. N., Jain, A., Gangrade, P., & Khan, A. (2025). A Graph-based Approach for Multi-Modal Question Answering from Flowcharts in Telecom Documents. *ArXiv*, *abs/2507.22938*. <https://doi.org/10.48550/arxiv.2507.22938>

Tanaka, R., Iki, T., Hasegawa, T., Nishida, K., Saito, K., & Suzuki, J. (2025). VDocRAG: Retrieval-Augmented Generation over Visually-Rich Documents. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 24827-24837. <https://doi.org/10.48550/arxiv.2504.09795>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is All You Need. *Advances in Neural Information Processing Systems*, 30. <https://arxiv.org/abs/1706.03762>

Zhang, J., Zhang, Q., Wang, B., Ouyang, L., Wen, Z., Li, Y., Chow, K., He, C., & Zhang, W. (2024). OCR Hinders RAG: Evaluating the Cascading Impact of OCR on Retrieval-Augmented Generation. *ArXiv*, *abs/2412.02592*. <https://doi.org/10.48550/arxiv.2412.02592>

ANEXO A
CATÁLOGO DE FALLAS COMUNES EN AIRES
ACONDICIONADOS TIPO SPLIT

Tabla A.1 Catálogo de fallas comunes en aires acondicionados tipo Split

Síntoma Observable	Posible Causa
El equipo no arranca y muestra error interno	Falla de memoria (EEPROM) en la tarjeta electrónica interior
El compresor no inicia y aparece error en unidad exterior	Falla de memoria EEPROM en la tarjeta electrónica exterior
El equipo se apaga solo y muestra código de error	Posible fuga de refrigerante o sensor defectuoso
El equipo no enfría y muestra error	Sensor de temperatura abierto o en corto
Funcionamiento irregular o apagado inesperado	Sensor de temperatura defectuoso
Error de lectura de temperatura	Sensor de temperatura dañado
El equipo se protege y se detiene	Sensor de temperatura defectuoso
Apagado por protección térmica	Sensor de temperatura fuera de rango
El equipo se apaga por protección eléctrica	Sobrecorriente o bloqueo del sistema
El equipo se detiene inmediatamente después de encender	Protección del módulo de potencia (IPM)
El equipo no detecta temperatura ambiente	Sensor ambiente abierto o en corto
El equipo no enfría correctamente	Sensor del evaporador defectuoso
Ventilador exterior no gira correctamente	Falla del motor del ventilador exterior
El display no responde o muestra error	Falla de comunicación entre tarjeta electrónica y display
Bajo rendimiento y apagado del sistema	Detección de fuga de refrigerante
El equipo no arranca	Falla en módulo de potencia (IPM)
El equipo se apaga por protección	Bajo voltaje de alimentación
Protección por voltaje alto	Sobrevoltaje en la línea eléctrica
El compresor no inicia	Falla de arranque del compresor

Fuente: Elaboración propia (2026), con base en manuales de servicio de los fabricantes analizados.

ANEXO B
INSTRUMENTO DE EVALUACIÓN Y TRANSCRIPCIONES
DE ENTREVISTAS

B.1 Instrumento de entrevista semiestructurada

El siguiente cuestionario se aplicó durante la fase de comprensión del problema (Capítulo 4) para caracterizar el perfil técnico de los entrevistados, documentar su flujo de diagnóstico y validar la necesidad operativa del prototipo. Las transcripciones de las respuestas obtenidas se presentan a continuación.

B.1.1 Introducción

“Esta entrevista es con fines académicos para un trabajo de graduación en Ingeniería Informática. Estamos desarrollando un asistente inteligente basado en Manuales de Servicio oficiales para apoyar a técnicos en mantenimiento de aires acondicionados tipo Split residenciales o comerciales ligeros. ¿Nos da su consentimiento para grabar y transcribir la entrevista?”

B.1.2 Bloque 1: Perfil técnico

1. ¿Cuántos años tiene trabajando en mantenimiento de aires acondicionados tipo Split?
2. ¿Cuenta con formación técnica formal o aprendió de manera empírica?
3. ¿Trabaja principalmente solo o en equipo?
4. ¿Atiende múltiples marcas o se especializa en algunas específicas?

B.1.3 Bloque 2: Proceso de diagnóstico y dificultades

5. Cuando llega a revisar un equipo que falla, ¿cuál es su secuencia típica de diagnóstico?
6. ¿En qué momento del proceso necesita consultar información externa (manual, internet, compañero de trabajo)?
7. ¿Qué tipo de fallas le obligan a buscar documentación? (Códigos de error, tarjetas electrónicas, sensores, fallas eléctricas, etc.)
8. Cuando no encuentra la información rápidamente, ¿qué suele ocurrir?
 - a. ¿Se retrasa el servicio?
 - b. ¿Hace prueba y error?
 - c. ¿Le ha ocurrido interpretar mal un manual?
9. ¿Qué tan fáciles de entender considera que son los manuales de servicio?

B.1.4 Bloque 3: Tiempo, productividad y documentación

10. Cuando necesita información técnica, ¿qué consulta primero?
 - Manual de servicio
 - Google

- YouTube
 - Grupos de técnicos
 - Otro
11. En promedio, ¿cuánto tiempo le toma encontrar la información cuando debe buscarla?
- Menos de 1 minuto
 - 1–5 minutos
 - Más de 5 minutos
12. Cuando necesita buscar información técnica y eso le toma varios minutos, ¿ese tiempo impacta la cantidad de servicios que puede realizar en el día? ¿Aproximadamente, cuántos equipos atiende en promedio por día?

B.1.5 Bloque 4: Uso y confianza en Inteligencia Artificial

13. ¿Ha utilizado herramientas como ChatGPT u otras IA para resolver fallas técnicas?
- **Si responde SÍ:**
 - En una escala del 1 al 10, ¿qué tan confiables han sido las respuestas?
 - ¿Le redujo el tiempo comparado con buscar en un manual?
 - ¿Alguna vez le dio una respuesta incorrecta?
 - ¿Confía más en IA o en manuales oficiales?
 - **Si responde NO:** ¿Cuál es la razón principal? (Desconfianza / Desconocimiento / Prefiere manuales oficiales / No lo considera necesario)
14. ¿Confía en la información que encuentra en grupos o YouTube? ¿Qué le preocupa más del uso de IA?
- Que invente información
 - Que no sea específica de la marca
 - Que sea muy general
 - Otro

B.1.6 Bloque 5: Validación del concepto del prototipo RAG

15. Si tuviera un asistente en su celular que:
- Solo responda basándose en Manuales de Servicio oficiales
 - Muestre el fragmento exacto del manual
 - Indique pasos numerados
 - Incluya diagramas eléctricos
- ¿Le sería útil?
16. ¿Lo usaría durante el servicio en campo o solo para capacitación?
17. ¿Estaría dispuesto a pagar por una herramienta así si realmente le ahorra tiempo?

B.2 Transcripciones de entrevistas

B.3 Entrevista 1: Edwin Roberto Quintanilla

Nombre: Edwin Roberto Quintanilla

¿Nos da su consentimiento para utilizar sus respuestas con fines académicos en esta investigación?

Sí, doy mi consentimiento.

¿Cuántos años tiene trabajando en mantenimiento de aires acondicionados tipo Split?

En refrigeración y mantenimientos de aires llevo 3 años.

¿Cuenta con formación técnica formal o aprendió de manera empírica?

Los conocimientos que adquirí sobre refrigeración y aires acondicionados tipo mini Split fueron de manera empírica. Ya que en mi anterior trabajo dieron unas capacitaciones con respecto a esta rama de refrigeración, sin embargo, pues no solo me quedé con lo aprendido en esas capacitaciones, sino que a la hora de estar ejecutando pues me tocó ir aprendiendo. Entonces, en esas capacitaciones que fueron informales, se podría decir, no me otorgaron algún título; entonces, por esa manera, sí puedo decir en mi respuesta que ha sido de manera empírica.

¿Trabaja principalmente solo o en equipo?

Actualmente, sí, trabajo principalmente solo.

¿Atiende múltiples marcas o se especializa en algunas específicas?

Con respecto a la hora de la manipulación de los aires acondicionados tipo mini Split, ya sea convencional o Inverter, la marca, pues no, no tengo una especialización con una marca en específica. Sin embargo, pues tengo marcas con las que estoy más familiarizado, ¿verdad? Como Midea, York, Andina, LG, Mitsubishi, con las que, pues, en ciertas ocasiones he logrado tener la interacción con ese tipo de equipo, ya sea para un mantenimiento, una instalación o una reparación.

Cuando llega a revisar un equipo que falla, ¿cuál es su secuencia típica de diagnóstico?

Pues para dar un buen diagnóstico de un aire acondicionado, lo primero que hago es conectar la pinza amperimétrica para ver el consumo del equipo con respecto a lo de la placa del fabricante, ¿verdad? Ya que, pues, cada fabricante tiene sus diferentes especificaciones. Entonces, conectar también los manómetros como segunda parte, para ver en cuántas presiones está el refrigerante, en cuántos PSI, y también comparar los PSI con respecto a lo que dice la placa del equipo, ¿verdad? Ya que cada equipo, pues, dependiendo su capacidad de BTUs, varía la cantidad de refrigerante que tiene que poseer en el

sistema, y también depende de la marca, ¿verdad? Ya que otros usan diferentes tipos de refrigerante. Entonces, como segundo paso es eso, ¿verdad? Encontrar, ver las mediciones. Ya después, con esos dos datos, parte el diagnóstico de si un componente eléctrico está dañado. Eso ya uno lo va viendo con respecto a cómo va destapando las unidades, ¿verdad? Tanto la evaporadora como la condensadora.

Y para seguir agregando más puntos, todo varía con respecto a lo que el cliente da como diagnóstico inicial, ¿verdad? Que el cliente dice: “el equipo huele mal”, “el equipo está botando agua”, “el equipo no está enfriando”. Porque los anteriores pasos que he dicho es cuando el equipo no está enfriando o, pues, ha tenido fallas o no enciende. Ya si está goteando, pues se entiende que cuando un equipo está botando agua es porque no ha tenido su mantenimiento, ya que se recomienda que sea cada seis meses. Ya que, aunque el equipo no se utilice, está la unidad que está en el exterior, entonces pues esa unidad siempre recibe la contaminación del aire, ¿verdad? Uno entiende que esa unidad está a la intemperie, entonces necesita que tenga sus mantenimientos al día para que pueda hacer una buena transmisión de calor.

Entonces, pues, con respecto a hacer un diagnóstico, lo principal siempre primero es tomar mediciones, ya sea de refrigerante, que sería con los manómetros, y con el amperímetro para ver cuánto está consumiendo y cuánto está llegando de voltaje a los bornes. Ya de ahí se parte a los siguientes desglosamientos de diagnóstico, ¿verdad? Ya que, bueno, algunos diagnósticos en el momento los va a ver uno; qué es lo que se necesita. Bueno, siempre es el que uno logra verificar qué es lo que está pasando, ¿verdad? Ya sea que al ventilador se le quemara su capacitor, o sus bobinas se sobrecalentaran, o que el capacitor pues ya estuviera dañado. O la placa, porque bueno, hoy en día los equipos Inverter pues son demasiado ahorrativos; sin embargo, pues, el hecho de tener tantos sensores y que sean muy electrónicos, al no tener sus protecciones a la hora de tener una buena instalación, pues muchas veces se terminan dañando las placas. Entonces, también a veces hay que inspeccionar los bornes de las placas para ver si también llegan a su voltaje, o si no hay algún componente que se pueda ver a la vista que esté dañado, pues uno con el tester hace las correctas mediciones correspondientes al tipo de componente que uno va a estar verificando.

¿En qué momento del proceso necesita consultar información externa (manual, internet, compañero de trabajo)?

Con respecto a su pregunta, tengo dos respuestas. Bueno, mi respuesta es para dos opciones, que sería tanto la ayuda de un compañero como la ayuda de Internet. Ya que, pues, el Internet es esencial en este rubro para tener tablas con respecto a cada equipo, qué componentes lleva, el diagrama eléctrico... Ya que muchas veces, si uno no es la persona que ha instalado el aire, pues la gente termina botando los manuales, ¿verdad? Entonces, para adquirir esa información de los manuales sí necesita Internet uno; ya que, pues, si bien el equipo trae sus placas donde tiene esas especificaciones de refrigerante, de voltaje, de consumo, siempre tener el manual de servicio es algo importante.

Y también menciono que más allá de tener el Internet, que es un aliado demasiado bueno, también pues si uno tiene algún compañero... pues pongo este contexto de que a veces la experiencia de otra persona que ya tuviera fallas parecidas, o pues el conocimiento de años en este rubro, también siento que tiene su ayuda. Que también eso es algo que, pues sí, si muy bien con el Internet uno puede llevarse, pues a veces el hecho de tener a una persona con experiencia en el rubro también va de la mano. Pero también esas personas que ya tienen años en ese rubro no pueden desenvolverse, ¿verdad?, de una manera óptima, se puede decir. Porque, bueno, hoy la tecnología va avanzando demasiado, que pues los refrigerantes cambian, las tecnologías de la electrónica de los aires cambian bastante porque siempre van mejorando. Entonces, si bien es bueno tener ahí a una persona con la cual te puedas apoyar con una pregunta, que te pueda ayudar, pues siempre se necesita el Internet. Ya que, pues, a veces es muy complicado el hecho de tener capacitaciones constantes de los proveedores de los equipos, ya que no siempre las hay, ¿verdad? Entonces, la manera en la cual uno se puede defender bastante con conocimientos que sean correctos (porque en este rubro no se puede equivocarse uno), pues es teniendo el Internet de la mano y saber buscar bien los manuales, porque eso es lo que lleva más tiempo.

¿Qué tipo de fallas le obligan a buscar documentación? (Códigos de error, tarjetas electrónicas, sensores, fallas eléctricas, etc.)

Bueno, de las fallas, se puede decir que más que todo para los códigos de error sí se necesita el Internet. Ya que, por mi caso, al tener un catálogo de varias marcas, pues no todas las veces el error es igual en todas las marcas. Entonces, sí, si bien en algunos errores cambian las palabras o son similares, no siempre el error “3” va a ser en Andina y luego va a ser en LG. Es muy difícil a veces que todos los errores sean muy iguales; siempre es mejor tener la base técnica en la cual uno no lo pueda estar, pues, inventando.

Cuando no encuentra la información rápidamente, ¿qué suele ocurrir?

Lo principal es que el servicio se retrasa. Ya que eso de la prueba y error retrasa todavía aún más, y pues el hecho de interpretar mal un manual... más que todo sería encontrar la información en el manual, porque el hecho de que uno esté interpretando un manual requiere tiempo. Entonces, la verdad es que el hecho de no tener el conocimiento a la mano, pues sí hace que un trabajo se extienda demasiado tiempo y pues ya no sea un trabajo que se puede ejecutar rápido, sino que por lo menos una hora, por decir un tiempo. Por el hecho de que, pues, siempre hay que tener la información correcta, no se puede buscar o usar prueba y error. Entonces, sí se necesita, sí o sí, una fuente muy confiable.

¿Le ha ocurrido interpretar mal un manual?

En mi caso no me ha pasado por el momento.

¿Qué tan fáciles de entender considera que son los manuales de servicio?

Siempre, pues, el manual es cuestión de perspectiva, ¿verdad? Ya que hay manuales que son de dife-

rentes marcas, más, se puede decir, accesibles a la interpretación, ¿verdad? Entonces siento que, en ese caso, ya sea a la hora de leer un manual de servicio, siempre más allá de que sea fácil o difícil entenderlo, requiere su tiempo. Ya que, pues, estar buscando justamente en el manual que es para el equipo la pregunta, consulta o el dato técnico que se necesita, pues sí requiere un esfuerzo, ¿verdad? Un esfuerzo y tiempo para poder tener una conclusión buena.

Cuando necesita información técnica, ¿qué consulta primero?

El principal sería Google, ya que pues allí está la mayoría, o si no es que todos los manuales de servicio. Pero es bastante lento, ya que el hecho de encontrar la marca, el manual, la página y el apartado de lo que estás buscando es un proceso que sí necesita su tiempo. Y que también viene quedando bastante lento, como YouTube; ya que, pues sí hay muchos videos empíricos que explican diferentes cuestiones con respecto a la refrigeración. Volvemos a que no es una base técnica como uno esperaría en un manual de servicio. Entonces sí, los dos son pues bastante eficientes en su manera... bueno, no se puede decir eficiente porque lleva bastante tiempo, pero los dos ayudan. Sin embargo, no dejan siempre eso que se desea para que uno pueda facilitarse más.

En promedio, ¿cuánto tiempo le toma encontrar la información cuando debe buscarla?

Definitivamente sí, serían más de cinco minutos.

Cuando necesita buscar información técnica y eso le toma varios minutos, ¿ese tiempo impacta la cantidad de servicios que puede realizar en el día?

La falta de información inmediata definitivamente perjudica el tiempo de la ejecución de los trabajos. Ya que así como se pueden ver en un día tres equipos, solamente se puede llegar a ver uno por el hecho de que muchas veces el tener un dato técnico del equipo, de la ficha técnica, o que se pueda llegar a encontrar el manual de servicio... y no tener eso a la mano, puede retrasar toda la operación.

Aproximadamente, ¿cuántos equipos atiende en promedio por día?

El entrevistado no proporcionó una respuesta específica.

¿Ha utilizado herramientas como ChatGPT u otras Inteligencias Artificiales para resolver fallas técnicas?

Sí, actualmente pues he intentado implementar poco a poco la inteligencia artificial para poder ayudarme en el día a día con el trabajo.

En una escala del 1 al 10, ¿qué tan confiables han sido las respuestas de la IA?

Sería un 10, ya que la inteligencia artificial es una herramienta que hoy en día está en una constante evolución y a pasos agigantados, y el hecho de poderla implementar en mi trabajo ha sido algo estupendo. Ya que, al poder brindarle el contexto y también saber cómo preguntar o qué es lo que estoy preguntando, podemos entender cómo llegar a una respuesta con esa confianza total. Entonces sí, está

muy bien hoy en día, pues, tener que la inteligencia artificial te ayude en algún tema. Bueno, en mi caso, en mi trabajo, me resulta a veces muy difícil, ya que pues me toma tiempo también el hecho de poder utilizarla de momento, porque tengo que... bueno, sería bueno que ella estuviera de la mano con el rubro de mi trabajo. Entonces, me ayuda bastante y puedo darle la confianza de 10; sin embargo, pues todavía siento que tuviera que trabajar más para llegar a la evolución que yo quisiera para poder implementarla en mi trabajo, pero esperaría que en su momento pueda tener algo parecido.

¿Le redujo el tiempo comparado con buscar en un manual?

Definitivamente sí; en comparación con los manuales, la inteligencia artificial me ha ayudado a ahorrar mucho más tiempo. Si podría decir que andar buscando en un manual podría ser de más de cinco minutos, la inteligencia artificial me acorta el tiempo bastante, bastante, bastante más.

¿Alguna vez le dio una respuesta incorrecta?

Respuestas incorrectas, mejor dicho, o respuestas con un contexto lejano a la pregunta que uno realiza. Ya que en ese caso siento que al no brindarle todo el contexto de que es un tema específico, como mi trabajo de refrigeración, pues muchas veces se puede quedar un poco corta la idea del conocimiento que brinda o la respuesta que uno necesita, ya que se sale un poco de contexto. Entonces, al tomarse uno el tiempo de poder elaborar unas preguntas y brindar el contexto, todo se soluciona. Sin embargo, lleva su tiempo, pero es mucho más sencillo que llevar una búsqueda en un manual de servicio.

¿Confía más en la IA o en manuales oficiales?

Pues al principio sí reconozco que siempre consultaba manuales de servicio. Sin embargo, pues, el tiempo de estar utilizando la inteligencia artificial me ha dado la confianza que también me transmiten los manuales de servicio para poder, pues, ejecutar mi trabajo con la inteligencia artificial de la mano. Y, definitivamente, buscar en manuales es mucho más tardado.

¿Confía en la información que encuentra en grupos de técnicos o YouTube?

Pues la verdad es que en grupos, foros o videos hay mucha información en la que uno, pues, puede confiar porque son de colegas que se dedican al mismo rubro. Sin embargo, pues uno no solo se puede quedar con el hecho de un video, sino que siempre hay que buscar en los manuales de servicio que son donde hay más información, y, en este caso que estaba implementando, usar Gemini para poder tener una respuesta más rápida.

¿Qué le preocupa más del uso de Inteligencia Artificial en su trabajo?

Lo principal es que es muy general. Ya que uno sí necesita estar enfocado en cada marca en su momento. Entonces la IA, al principio, es muy general y es donde uno puede cometer el error de no darle contexto y llegar a entender algo que no se puede hacer. Y pues si uno en este rubro hace algo que no va con respecto al fabricante que está en el manual de servicio, pues ahí uno termina demasiado mal, en problemas, arruinando el equipo. Entonces, sí, uno puede utilizar la IA, la idea es buena

porque es rápida y tiene mucha información, pero también uno tiene que saber usar la herramienta. Y pues también, que la herramienta fuera más especializada en lo que necesito, ¿verdad? En cada marca.

Si tuviera un asistente en su celular que solo responda basándose en Manuales de Servicio oficiales, muestre el fragmento exacto del manual, indique pasos numerados e incluya diagramas eléctricos, ¿le sería útil?

Claramente sería útil. Ya que en mi rubro, ¿verdad?, que tengo un catálogo de diferentes marcas, el hecho de tener el manual de servicio de cada equipo, de cada marca, no es tan viable... bueno, para nada. Entonces, tener a la palma de mis manos el manual de servicio, o una herramienta que pueda ayudarme a interpretar el manual, o buscarme más allá de interpretar, y luego asegurarse que en el manual está esa información, sería estupendo.

¿Lo usaría durante el servicio en campo o solo para capacitación?

Es que, el hecho de tener a un asistente tan accesible y con unas funciones demasiado buenas, se tiene que usar sí o sí en el campo y para capacitaciones. Ya que es una herramienta... podría decir que se convertiría en una de las herramientas principales. El hecho de tener ese asistente, como en este rubro, ¿verdad?, es bueno tener un teléfono solo para el trabajo. El hecho es que, tener siempre cargado ese teléfono, es como dejar los manómetros en refrigeración, no se puede olvidar. Entonces, si llega a existir una herramienta con todas esas funciones, sí o sí se tiene que utilizar día a día.

Y sería una herramienta que a los colegas que están en este rubro de refrigeración les fascinaría, ya que simplemente con el hecho de saber que pudiera haber una inteligencia artificial con esas funciones, es muy increíble.

B.4 Entrevista 2: Daniel

¿Cuántos años tiene trabajando en mantenimiento de aires acondicionados tipo Split?

Aproximadamente 3 años y medio.

¿Cuenta con formación técnica formal o aprendió de manera empírica?

Formación técnica.

¿Trabaja principalmente solo o en equipo?

Por lo general solo, aunque a veces se hacen instalaciones de aires en equipo.

¿Atiende múltiples marcas o se especializa en algunas específicas?

Atiende cualquier tipo de marcas de aires acondicionado.

Cuando llega a revisar un equipo que falla, ¿cuál es su secuencia típica de diagnóstico?

Menciona que todo depende de la falla que se esté presentando en el equipo, pero por lo general inicia con pruebas de encendido y apagado, pruebas de enfriamiento y procede con pruebas eléctricas.

¿En qué momento del proceso necesita consultar información externa (manual, internet, compañero de trabajo)?

Por lo general cuando es un error poco usual.

¿Qué tipo de fallas le obligan a buscar documentación? (Códigos de error, tarjetas electrónicas, sensores, fallas eléctricas, etc.)

Falla de sensores, fallas eléctricas, fallo de algún componente.

Cuando no encuentra la información rápidamente, ¿qué suele ocurrir?

En general se retrasa el servicio, y dependiendo si no es un error muy complejo procede a hacer prueba y error, siempre manteniendo el cuidado. Mencionó que sí le ha pasado que interpretó mal un manual, ya que al ser algo extensos y confusos, suele pasar que no se interpreta a la perfección.

¿Qué tan fáciles de entender considera que son los manuales de servicio?

Poco intuitivos y bastante tediosos de leer por lo general.

Cuando necesita información técnica, ¿qué consulta primero?

Directamente a una IA, en este caso mencionó ChatGPT, y esta persona le pasa los manuales técnicos que usa la empresa.

En promedio, ¿cuánto tiempo le toma encontrar la información cuando debe buscarla?

En promedio 1–5 minutos usando IA; si es de forma manual, más de 5 minutos.

Cuando necesita buscar información técnica y eso le toma varios minutos, ¿ese tiempo impacta la cantidad de servicios que puede realizar en el día?

Impacta de forma considerable, ya que retrasa mucho los siguientes servicios. Por lo general hace entre 7–8 servicios por día.

¿Ha utilizado herramientas como ChatGPT u otras IA para resolver fallas técnicas?

Sí, ChatGPT.

En una escala del 1 al 10, ¿qué tan confiables han sido las respuestas?

Lo considera un 8 sobre 10, a nivel de confianza.

¿Le redujo el tiempo comparado con buscar en un manual?

Sin duda, le ahorra muchísimo tiempo.

¿Alguna vez le dio una respuesta incorrecta?

Completamente incorrecta no, pero a veces es redundante con las respuestas, y se mantiene en el mismo círculo sin profundizar más.

¿Confía más en IA o en manuales oficiales?

En este caso menciona que en la IA, por el hecho que le pasa directamente el manual técnico y se basa puramente en ello.

¿Confía en la información que encuentra en grupos o YouTube?

Sí, por lo general al tener el conocimiento, según lo que ha buscado considera que ha sido información correcta y útil.

¿Qué le preocupa más del uso de IA?

Que brinde información errónea en algún punto.

Si tuviera un asistente en su celular que solo responda basándose en Manuales de Servicio oficiales, muestre el fragmento exacto del manual, indique pasos numerados e incluya diagramas eléctricos, ¿le sería útil?

Sin duda, menciona que sería muy útil.

¿Lo usaría durante el servicio en campo o solo para capacitación?

En ambos casos, principalmente más en servicio, ya que simplifica y ahorra mucho tiempo.

¿Estaría dispuesto a pagar por una herramienta así si realmente le ahorra tiempo?

Sí, el entrevistado menciona que actualmente paga ChatGPT, y sin duda considera que le ahorra bastante tiempo en su trabajo, para ser más productivo, y sin duda pagaría algo que estuviera mucho más especializado en dicho campo.

B.5 Entrevista 3: Técnico con formación en ingeniería mecánica

¿Cuántos años tiene trabajando en mantenimiento de aires acondicionados tipo Split?

He trabajado en el rubro por 6 meses.

¿Cuenta con formación técnica formal o aprendió de manera empírica?

Formación universitaria en ingeniería mecánica.

¿Trabaja principalmente solo o en equipo?

Usualmente en equipo.

¿Atiende múltiples marcas o se especializa en algunas específicas?

He trabajado múltiples marcas y diferentes dispositivos.

Cuando llega a revisar un equipo que falla, ¿cuál es su secuencia típica de diagnóstico?

Verificar la falla reportada, realizar preguntas, consultar información o manuales y solucionar el problema.

¿En qué momento del proceso necesita consultar información externa (manual, internet, compañero de trabajo)?

Cuando ya no encuentro la información por mi cuenta o necesito una segunda opinión.

¿Qué tipo de fallas le obligan a buscar documentación? Cuando no encuentra la información rápidamente, ¿qué suele ocurrir?

Cuando los dispositivos muestran códigos de error me veo forzado a consultar en internet. El servicio puede retrasarse dependiendo de la complejidad y a veces toca hacer prueba y error, los manuales se interpretan bien sin tanta complicación.

¿Qué tan fáciles de entender considera que son los manuales de servicio?

Son fáciles de entender, pero muchos manuales considero que están incompletos o sería bueno que el fabricante diera más información.

Cuando necesita información técnica, ¿qué consulta primero?

Si tuviera que ponerles un orden: primero YouTube, segundo grupos de técnicos, luego manuales de servicios y Google.

En promedio, ¿cuánto tiempo le toma encontrar la información cuando debe buscarla?

Por lo general suele durar de 1 a 5 minutos.

Cuando necesita buscar información técnica y eso le toma varios minutos, ¿ese tiempo impacta la cantidad de servicios que puede realizar en el día? Aproximadamente, ¿cuántos equipos atiende en promedio por día?

No impacta mucho, a menos que verdaderamente sea algo muy complejo. Por lo general si es mantenimiento correctivo, 3 equipos y si son rutinas preventivas o correctivas leves ya programadas pueden ser 6 equipos.

¿Ha utilizado herramientas como ChatGPT u otras IA para resolver fallas técnicas?

Sí las he utilizado para resolver fallas técnicas. Por lo general, las respuestas son confiables; en una escala de 1 al 10 diría que 7. Sí ayuda, es menor el tiempo a manualmente consultar un documento o manual, pero siempre hay que validar la información.

¿Confía en la información que encuentra en grupos o YouTube? ¿Qué le preocupa más del uso de IA?

Sí confío en la información de grupos y YouTube. Me preocupa que sea una respuesta muy general y no abunde en la información.

Si tuviera un asistente en su celular que solo responda basándose en Manuales de Servicio oficiales, muestre el fragmento exacto del manual, indique pasos numerados e incluya diagramas eléctricos, ¿le sería útil?

Que el asistente indique pasos numerados de cómo solucionar o dar mantenimiento, e incluya diagramas eléctricos.

¿Lo usaría durante el servicio en campo o solo para capacitación?

Lo usaría para ambos, tal vez más para capacitación.

¿Estaría dispuesto a pagar por una herramienta así si realmente le ahorra tiempo?

No, creo que es un poco exagerado ya que la verdad no realiza mucho para que sea justificado pagar por ello.

ANEXO C

DISEÑO FINAL DE LA INTERFAZ DE USUARIO

A continuación se presentan las capturas de pantalla correspondientes al diseño final de la interfaz gráfica web del sistema de Generación Aumentada por Recuperación. Estas evidencias documentan los componentes funcionales implementados en la aplicación desplegada: el asistente conversacional para consultas de diagnóstico técnico, el módulo de gestión documental para la carga y administración de manuales técnicos, el flujo de importación e indexación de documentos para el motor RAG, la sección de configuración institucional y el mecanismo de selección de cuentas de usuario en el entorno de demostración.




Figura C.1 Interfaz principal del asistente de diagnóstico




Figura C.2 Consulta de diagnóstico con respuesta del asistente RAG




Figura C.3 Módulo de gestión y carga de manuales técnicos




Figura C.4 Proceso de importación e indexación de manuales técnicos




Figura C.5 Módulo de configuración y créditos institucionales



Figura C.6 Selector de cuentas de usuario en entorno de demostración