

UNIVERSIDAD CENTROAMERICANA
JOSÉ SIMEÓN CAÑAS



SISTEMA DE GENERACIÓN AUMENTADA POR RECUPERACIÓN
(RAG) PARA DIAGNÓSTICO Y MANTENIMIENTO DE AIRES
ACONDICIONADOS TIPO SPLIT

TRABAJO DE GRADUACIÓN PREPARADO PARA LA
FACULTAD DE INGENIERÍA Y ARQUITECTURA

PARA OPTAR AL GRADO DE
INGENIERA INFORMÁTICA

POR:

RODRIGO ANDRÉS MENA CABALLERO
DUGLAS FERNANDO PINEDA FUENTES
MARIO ANTONIO MARTINEZ VILLATORO

MAYO 2026
ANTIGUO CUSCATLÁN, EL SALVADOR, C.A.

RECTOR
MARIO ERNESTO CORNEJO MENA, S.J.

SECRETARIA GENERAL
LIDIA GABRIELA BOLAÑOS TEODORO

DECANO DE LA FACULTAD DE INGENIERÍA Y ARQUITECTURA
CARLOS ERNESTO RIVAS CERNA

DIRECTOR DE LA CARRERA DE INGENIERÍA INFORMÁTICA
JOSÉ ENMANUEL AMAYA ARAÚJO

DIRECTOR DEL TRABAJO
JAMES EDWARD HUMBERSTONE MORALES

LECTOR
NOMBRE DEL LECTOR

AGRADECIMIENTOS

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Mauris eget arcu id justo mollis sagittis. Integer commodo vitae libero eget sagittis. Etiam id ante dignissim, sollicitudin odio id, rhoncus magna. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia curae; Praesent at tortor eros. Aenean in euismod mauris. Suspendisse pharetra aliquet ex, sed tempus augue aliquam nec. Donec tempor molestie mi, quis faucibus sem. Cras ornare bibendum nulla a laoreet. Vestibulum risus massa, feugiat at eros ut, rhoncus aliquam turpis.

RESUMEN

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Mauris eget arcu id justo mollis sagittis. Integer commodo vitae libero eget sagittis. Etiam id ante dignissim, sollicitudin odio id, rhoncus magna. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia curae; Praesent at tortor eros. Aenean in euismod mauris. Suspendisse pharetra aliquet ex, sed tempus augue aliquam nec. Donec tempor molestie mi, quis faucibus sem. Cras ornare bibendum nulla a laoreet. Vestibulum risus massa, feugiat at eros ut, rhoncus aliquam turpis.

In malesuada aliquet orci ac rutrum. Donec dignissim lectus eu ante venenatis semper. Aliquam leo ligula, vehicula ac sagittis non, consectetur nec dui. Pellentesque at arcu diam. Aliquam dignissim condimentum auctor. Nulla vehicula et quam vitae scelerisque. Phasellus bibendum posuere egestas. Donec vel nunc massa. Etiam posuere est urna, eu bibendum mauris semper ut. Suspendisse rutrum purus in metus tristique, nec sagittis arcu posuere. Vestibulum tempus pellentesque est sit amet eleifend. Phasellus fringilla neque nec est mattis, sed varius nisi tristique. Pellentesque ullamcorper massa ut orci rutrum pretium.

Nullam tempor elit id lectus maximus, eu congue mauris consequat. Vestibulum facilisis ac lectus eu volutpat. Maecenas ac ante erat. Nunc sit amet velit dapibus, tincidunt risus quis, sagittis est. Aliquam dapibus commodo enim, ut tempor sem accumsan nec. Sed non scelerisque velit. Ut accumsan ullamcorper dui at lacinia.

Morbi blandit molestie lectus non tincidunt. Nam id imperdiet nisi. Proin sed risus vehicula, malesuada tellus nec, dapibus magna. Cras vitae dolor lorem. Morbi vel arcu sit amet dolor auctor facilisis ac nec arcu. Pellentesque congue vulputate ligula, ac tempus metus porttitor sit amet. Aliquam egestas ultricies cursus. Mauris sit amet blandit elit. Cras ac nunc et enim aliquam efficitur. Suspendisse potenti. Integer accumsan turpis ut posuere hendrerit.

Vestibulum vel nisi turpis. Donec pellentesque odio sodales, facilisis elit ac, finibus libero. Maecenas in turpis eget sapien volutpat finibus sed a turpis. In a aliquet magna. Nullam et molestie tellus. In bibendum nunc tortor, eget malesuada turpis tincidunt vitae. Praesent non nulla semper ligula euismod facilisis ac at mauris. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia curae; Aliquam non faucibus dolor. In hac habitasse platea dictumst. Sed accumsan rutrum fringilla. In ac magna nunc. Praesent ac convallis magna.

ÍNDICE

RESUMEN	i
ÍNDICE DE FIGURAS	iv
ÍNDICE DE TABLAS	vi
SIGLAS	ix
CAPÍTULO 1. INTRODUCCIÓN	1
1.1 Planteamiento del problema	1
1.2 Antecedentes	1
1.3 Alcances y limitaciones	2
1.3.1 Alcances.....	2
1.3.2 Limitaciones.....	3
1.4 Objetivos	3
1.4.1 Objetivo general	3
1.4.2 Objetivos específicos	3
CAPÍTULO 2. ESTRUCTURA DEL TRABAJO	5
CAPÍTULO 3. MARCO TEÓRICO	7
3.1 Procesamiento de Lenguaje Natural (PLN)	7
3.2 Modelos de Lenguaje de Gran Escala (LLM) y Arquitectura Transformer	7
3.2.1 Limitaciones de los LLM Tradicionales y Problema de Alucinación	8
3.3 Embeddings y Representación Semántica.....	8
3.4 Bases de Datos Vectoriales y Búsqueda Semántica	9
3.5 Generación Aumentada por Recuperación (RAG)	9
3.6 Framework LlamaIndex.....	11
CAPÍTULO 4. METODOLOGÍA	13
CAPÍTULO 5. PRESENTACIÓN, ANÁLISIS E INTERPRETACIÓN DE RESULTADOS	15
CAPÍTULO 6. CONCLUSIONES Y RECOMENDACIONES	17
6.1 Conclusiones	17
6.2 Recomendaciones	17
REFERENCIAS	19

ANEXOS

ANEXO A.	Primer anexo
ANEXO B.	Segundo anexo
ANEXO C.	Tercer anexo

ÍNDICE DE FIGURAS

Figura 3.1	Arquitectura del Sistema de Generación Aumentada por Recuperación (RAG).....	10
------------	--	----

ÍNDICE DE TABLAS

SIGLAS

FIA: Facultad de Ingeniería y Arquitectura

UCA: Universidad Centroamericana José Simeón Cañas

CAPÍTULO 1. INTRODUCCIÓN

1.1 Planteamiento del problema

En los entornos de soporte técnico y mantenimiento de sistemas de aire acondicionado tipo Split, gran parte del conocimiento especializado necesario para resolver fallas precisas se encuentra distribuido de manera dispersa en extensos manuales de servicio, reportes de fallas, bitácoras y diversa documentación técnica. El acceso manual a esta información para diagnosticar componentes como tarjetas electrónicas, sensores o sistemas de control es un proceso que suele ser lento, inconsistente y dependiente de la experiencia individual de cada técnico.

De acuerdo con las entrevistas realizadas a profesionales del sector¹, la búsqueda manual de datos técnicos, diagramas o códigos de error toma en promedio entre uno y más de cinco minutos por consulta. Esta falta de información inmediata retrasa significativamente el tiempo de atención de cada servicio y, en consecuencia, impacta de forma directa y negativa en la productividad, reduciendo la cantidad de mantenimientos o reparaciones que los profesionales pueden concretar durante su jornada diaria.

Ante esta dificultad, los técnicos recurren a fuentes no estructuradas como foros en línea y herramientas de Inteligencia Artificial (IA) genéricas para agilizar sus diagnósticos. Sin embargo, estas alternativas presentan una limitante crítica: las respuestas suelen ser demasiado generales y carecen del contexto técnico específico de cada fabricante. Además, la IA tradicional frecuentemente redundante en la información que entrega, manteniéndose en un círculo de explicaciones superficiales sin profundizar en la solución real requerida para el equipo. Existe, por tanto, un vacío tecnológico claro entre la necesidad de inmediatez del técnico y la exactitud que exigen los manuales de servicio oficiales.

1.2 Antecedentes

Las entrevistas realizadas a cuatro profesionales con perfiles variados y entre seis meses y ocho años de experiencia —con formación tanto técnica formal como empírica— validaron la magnitud del problema descrito (véase Anexo B). La totalidad de los entrevistados ha recurrido a herramientas de inteligencia artificial para apoyar sus diagnósticos, calificándolas entre siete y diez sobre diez en confiabilidad. No obstante, a pesar de esta valoración positiva, coinciden en señalar sus limitaciones de forma contundente: un técnico con tres años y medio de experiencia que paga una suscripción a una herramienta de IA y le carga manuales directamente reportó que la herramienta “se mantiene en el mismo círculo sin profundizar más”, mientras que otro profesional con tres años de trayectoria advirtió que actuar con información descontextualizada respecto al fabricante genera diagnósticos erróneos, evidenciando un riesgo operativo real.

¹Las transcripciones completas de las entrevistas se encuentran en el Anexo B.

Este déficit también se refleja en la productividad: el técnico con mayor carga de trabajo atiende entre siete y ocho equipos diarios y señaló que los retrasos por búsqueda de información afectan considerablemente los servicios siguientes, en tanto que otro entrevistado indicó que, en casos de alta complejidad, la ausencia de datos técnicos a la mano puede reducir la atención a un único equipo en toda la jornada.

Ante este escenario, los cuatro profesionales manifestaron de forma unánime su interés en un asistente especializado que muestre el fragmento exacto del documento, proporcione pasos numerados e incluya diagramas técnicos; características que, según los entrevistados, eliminarían la ambigüedad de las respuestas genéricas y reducirían el margen de error en diagnósticos que exigen valores precisos de voltaje, resistencia o configuración de sensores. Esta necesidad operativa no resuelta constituye el antecedente directo que motiva el presente proyecto.

1.3 Alcances y limitaciones

1.3.1 Alcances

Para dar respuesta a la necesidad operativa de agilizar los diagnósticos técnicos, el proyecto se centra en el diseño y desarrollo de un prototipo funcional basado en la arquitectura de Generación Aumentada por Recuperación (RAG). El ámbito de aplicación abarca exclusivamente los sistemas de aire acondicionado tipo Split de muro o pared, instalados en entornos residenciales y comerciales ligeros. Específicamente, el asistente brindará soporte para equipos con tecnología Inverter y convencional que operen dentro de un rango de capacidad térmica de 9,000 a 24,000 BTU.

A nivel de hardware, el marco de diagnóstico de la herramienta contempla el análisis de los componentes principales que estructuran estos equipos: la unidad interior, la unidad exterior, los sistemas de control, los sensores de temperatura y el sistema de drenaje. Para asegurar la viabilidad del desarrollo dentro de los plazos establecidos, el dominio operativo se acota a la resolución de exactamente quince fallas comunes y repetibles asociadas a dichos componentes, cuyo listado exhaustivo y categorización se documentan en el Anexo A.

El motor de conocimiento del sistema se alimenta mediante un corpus técnico compuesto en su totalidad por manuales de servicio oficiales. Como resultado final, se construye un prototipo de software funcional, accesible a través de una interfaz de usuario, capaz de procesar consultas formuladas en lenguaje natural. Este aplicativo genera hipótesis de causa, secuencias de pasos para el diagnóstico y recomendaciones de mantenimiento básico, garantizando en todo momento la referenciación exacta del fragmento documental de origen que fundamenta la respuesta.

1.3.2 Limitaciones

- **No entrenamiento de modelos fundacionales:** El sistema no entrenará Modelos de Lenguaje de Gran Escala (LLM) desde cero; la solución integrará modelos preentrenados mediante el uso de frameworks existentes.
- **Ausencia de autonomía de diagnóstico:** El sistema no actuará como una entidad de diagnóstico autónoma; operará estrictamente como un asistente de apoyo para acelerar la búsqueda de información, mientras que la toma de decisiones finales recaerá siempre en el criterio del técnico humano.
- **Respaldo documental obligatorio:** El prototipo no generará recomendaciones empíricas ni respuestas que carezcan de un respaldo documental explícito dentro de la base de datos vectorial.

1.4 Objetivos

1.4.1 Objetivo general

Implementar un prototipo funcional del asistente que permita la interacción directa con el técnico.

1.4.2 Objetivos específicos

- Definir el catálogo de fallas con el que se construirá el sistema RAG.
- Diseñar el proceso de diagnóstico de fallas, incluyendo los prompts iniciales y el flujo de conversación esperado.
- Analizar el proceso de diagnóstico de fallas en aires acondicionados tipo Split para alinear las respuestas del sistema con el flujo de trabajo real de los técnicos.
- Construir un repositorio documental curado a partir de manuales técnicos de servicio, reportes de fallas y registros históricos de los fabricantes.
- Integrar un modelo de lenguaje que genere recomendaciones basadas exclusivamente en la información recuperada de las fuentes documentales oficiales.
- Evaluar el sistema en términos de utilidad, precisión percibida y reducción del esfuerzo y tiempo de búsqueda manual frente a los métodos tradicionales.
- Diseñar el instrumento de evaluación para la encuesta a los usuarios finales.

CAPÍTULO 2. ESTRUCTURA DEL TRABAJO

El presente documento se organiza en seis capítulos que siguen una progresión lógica desde la identificación del problema hasta las conclusiones derivadas del desarrollo del prototipo. A continuación se describe brevemente el contenido de cada uno de ellos.

El Capítulo 1, Introducción, expone el planteamiento del problema que motiva el proyecto, describiendo las dificultades que enfrentan los técnicos de mantenimiento al acceder a información especializada de manera oportuna. Se presentan también los antecedentes obtenidos a partir de entrevistas con profesionales del sector, el alcance y las limitaciones operativas del sistema, así como el objetivo general y los objetivos específicos que guían el desarrollo.

El Capítulo 2, Estructura del Trabajo, corresponde al presente capítulo y tiene como propósito orientar al lector sobre la organización del documento, describiendo de forma sintética el contenido de cada sección y la relación entre ellas.

El Capítulo 3, Marco Teórico, fundamenta conceptualmente el proyecto. Se abordan los principios del Procesamiento de Lenguaje Natural (PLN), los Modelos de Lenguaje de Gran Escala (LLM) y su arquitectura Transformer, el problema de la alucinación en sistemas generativos, la representación semántica mediante embeddings, las bases de datos vectoriales y la búsqueda por similitud, la arquitectura de Generación Aumentada por Recuperación (RAG) y el framework LlamaIndex utilizado como capa de integración. Este capítulo incluye una figura explicativa del flujo completo del sistema RAG.

El Capítulo 4, Metodología, describe el proceso de desarrollo del prototipo estructurado bajo la metodología CRISP-DM. Se documenta cada una de sus seis fases: comprensión del problema, comprensión de los datos, preparación de los datos, modelado, evaluación e implementación. Se detallan las decisiones técnicas tomadas en el benchmarking, incluyendo la selección del modelo de embeddings Gemini Embedding 001, el modelo generativo Gemini 1.5 Pro y la base de datos vectorial ChromaDB, así como las estrategias de ingesta y particionado de los manuales de servicio.

El Capítulo 5, Presentación, Análisis e Interpretación de Resultados, expone los hallazgos obtenidos durante la fase de evaluación del prototipo. Se presenta la tabla resumen de pruebas técnicas, las lecciones aprendidas derivadas de errores y hallazgos durante el desarrollo, y los resultados de la evaluación de la herramienta por parte de los técnicos usuarios.

El Capítulo 6, Conclusiones y Recomendaciones, sintetiza los principales logros del proyecto en relación con los objetivos planteados y propone líneas de trabajo futuro sustentadas en bibliografía científica, tales como el uso de bases de datos vectoriales avanzadas, técnicas de expansión de con-

sultas y representación mediante grafos de conocimiento.

Finalmente, el documento incluye dos anexos: el Anexo A contiene el catálogo exhaustivo de las quince fallas documentadas que conforman el dominio del sistema, y el Anexo B presenta el instrumento de evaluación y las transcripciones de las entrevistas realizadas a los técnicos durante la fase de comprensión del problema.

CAPÍTULO 3. MARCO TEÓRICO

Este capítulo presenta los fundamentos teóricos y las tecnologías subyacentes que sustentan el diseño e implementación del asistente inteligente. Se abordan los conceptos de Procesamiento de Lenguaje Natural, los Modelos de Lenguaje de Gran Escala y su arquitectura Transformer, el problema de la alucinación, la representación semántica mediante embeddings, las bases de datos vectoriales, la arquitectura de Generación Aumentada por Recuperación (RAG) y el framework LlamaIndex utilizado como capa de integración.

3.1 Procesamiento de Lenguaje Natural (PLN)

El Procesamiento de Lenguaje Natural (PLN) es una subdisciplina de la Inteligencia Artificial que estudia la interacción entre las computadoras y el lenguaje humano. Su objetivo principal es permitir que los sistemas computacionales comprendan, interpreten y generen lenguaje natural de forma significativa. El PLN combina técnicas de lingüística computacional, aprendizaje automático, modelado estadístico y redes neuronales profundas (Jurafsky & Martin, 2023).

En el contexto de sistemas técnicos, el PLN permite analizar documentación especializada (manuales de servicio, reportes técnicos, bitácoras) y convertir texto no estructurado en información procesable por un sistema inteligente.

Para el presente proyecto, el PLN es la base que permite interpretar preguntas formuladas por técnicos en lenguaje natural, comprender términos técnicos como códigos de error, voltajes, resistencias o configuraciones de sensores, y relacionar dichas consultas con fragmentos específicos de manuales oficiales.

3.2 Modelos de Lenguaje de Gran Escala (LLM) y Arquitectura Transformer

Los Modelos de Lenguaje de Gran Escala (Large Language Models, LLM) son modelos de aprendizaje profundo entrenados con grandes volúmenes de texto para predecir y generar lenguaje coherente (Brown et al., 2020).

La mayoría de los LLM modernos están basados en la arquitectura Transformer, introducida por Vaswani et al. (2017) en el artículo “Attention Is All You Need”. Esta arquitectura utiliza un mecanismo llamado autoatención (self-attention) que permite al modelo evaluar la relevancia de cada palabra respecto a las demás dentro de una secuencia.

Entre las características principales de los Transformers se encuentran el procesamiento paralelo de secuencias, la captura eficiente de dependencias de largo alcance y una mejor comprensión contextual

que los modelos recurrentes tradicionales.

Sin embargo, los LLM presentan limitaciones importantes: pueden generar información incorrecta (alucinaciones), no garantizan precisión técnica en dominios especializados y no tienen acceso dinámico a documentación específica salvo que se integre un sistema de recuperación externa.

En el contexto del diagnóstico de equipos tipo Split, depender únicamente de un LLM generalista puede producir respuestas ambiguas o no alineadas con especificaciones del fabricante.

3.2.1 Limitaciones de los LLM Tradicionales y Problema de Alucinación

Uno de los principales problemas documentados en los LLM es la alucinación, fenómeno en el que el modelo genera información plausible pero incorrecta o no respaldada por una fuente verificable (Ji et al., 2023).

En entornos técnicos críticos, como el diagnóstico eléctrico o electrónico, este comportamiento representa un riesgo operativo real, ya que decisiones incorrectas pueden provocar daños en componentes, generar diagnósticos erróneos, incrementar tiempos de reparación y afectar la seguridad del técnico.

Diversos estudios recientes (Ji et al., 2023; Lewis et al., 2020) han señalado que los LLM sin acceso a fuentes externas estructuradas tienden a completar respuestas con conocimiento estadístico aprendido durante el entrenamiento, lo cual no garantiza exactitud técnica específica por fabricante.

Por ello, surge la necesidad de integrar mecanismos de recuperación de información controlada.

3.3 Embeddings y Representación Semántica

Los embeddings son representaciones vectoriales de palabras, frases o documentos en un espacio matemático de múltiples dimensiones. Su propósito es capturar relaciones semánticas entre conceptos (Mikolov et al., 2013).

En lugar de representar texto como simples palabras clave, los embeddings permiten que términos conceptualmente similares se ubiquen cerca en el espacio vectorial. Por ejemplo, términos como “Sensor NTC”, “Termistor” y “Sensor de temperatura evaporador”, aunque no sean idénticos, pueden tener proximidad semántica en el espacio vectorial, permitiendo búsquedas más inteligentes.

Esta representación es clave para la búsqueda semántica, que supera la búsqueda tradicional basada en coincidencia exacta de palabras.

3.4 Bases de Datos Vectoriales y Búsqueda Semántica

Las bases de datos tradicionales (relacionales o NoSQL) están diseñadas para búsquedas estructuradas basadas en campos específicos o coincidencias exactas.

En contraste, las bases de datos vectoriales almacenan embeddings y permiten búsquedas por similitud utilizando métricas como la similitud coseno, la distancia euclidiana y el producto punto. Esto permite encontrar fragmentos de documentos que sean semánticamente relevantes aunque no compartan exactamente las mismas palabras.

En el caso de manuales técnicos extensos, una base vectorial permite dividir documentos en fragmentos, convertirlos en embeddings y recuperar únicamente los fragmentos más relevantes según la consulta del técnico. Esta tecnología es esencial para implementar sistemas de recuperación eficiente sobre documentación especializada.

3.5 Generación Aumentada por Recuperación (RAG)

La Generación Aumentada por Recuperación (Retrieval-Augmented Generation, RAG) es una arquitectura que combina un sistema de recuperación de información (base de datos vectorial) con un modelo generativo (LLM) (Lewis et al., 2020).

En lugar de depender únicamente del conocimiento interno del modelo, RAG permite que el LLM recupere primero fragmentos relevantes de documentos oficiales y genere una respuesta basada exclusivamente en ese contexto recuperado. Esto reduce significativamente el problema de alucinación y aumenta la precisión técnica.

En el proyecto propuesto, el flujo es el siguiente: el técnico formula una consulta, el sistema genera el embedding de la consulta, se buscan fragmentos relevantes en la base vectorial, el LLM genera una respuesta utilizando únicamente esos fragmentos y, finalmente, se muestra el fragmento exacto del manual como respaldo.

Este enfoque permite cumplir con el requisito identificado en las entrevistas: mostrar información específica del fabricante y pasos numerados directamente desde el manual. Como se ilustra en la Figura 3.1, el flujo del sistema se divide en una etapa de recuperación semántica y una etapa de generación fundamentada, ambas orquestadas por el framework LlamaIndex como capa de integración.



figure 3.1 Arquitectura del Sistema de Generación Aumentada por Recuperación (RAG). Fuente: [Elaboración propia]

3.6 Framework LlamaIndex

LlamaIndex es un framework diseñado para facilitar la integración entre fuentes de datos externas y modelos LLM (LlamaIndex, 2024). Su función principal es ingestar documentos, fragmentarlos, generar embeddings, indexarlos y conectarlos con modelos generativos.

De este modo, LlamaIndex permite construir aplicaciones basadas en arquitectura RAG de manera estructurada, facilitando la indexación de manuales técnicos, el control sobre las fuentes utilizadas y la generación de respuestas respaldadas por contexto verificable.

En este proyecto, LlamaIndex actúa como la capa intermedia que conecta los manuales de servicio con el modelo generativo y la base vectorial.

CAPÍTULO 4. METODOLOGÍA

CAPÍTULO 5. PRESENTACIÓN, ANÁLISIS E INTERPRETACIÓN DE RESULTADOS

CAPÍTULO 6. CONCLUSIONES Y RECOMENDACIONES

6.1 Conclusiones

6.2 Recomendaciones

REFERENCIAS

- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., et al. (2020). Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems*, 33, 1877-1901. <https://papers.nips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>
- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, 55(12). <https://arxiv.org/abs/2304.00361>
- Jurafsky, D., & Martin, J. H. (2023). *Speech and Language Processing* (3.^a ed.) [Draft]. Stanford University. <https://web.stanford.edu/~jurafsky/slp3/>
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems*, 33. <https://arxiv.org/abs/2005.11401>
- LlamaIndex. (2024). *LlamaIndex Documentation*. Consultado el 8 de abril de 2026, desde <https://docs.llamaindex.ai>
- Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient Estimation of Word Representations in Vector Space. *arXiv preprint arXiv:1301.3781*. <https://arxiv.org/abs/1301.3781>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is All You Need. *Advances in Neural Information Processing Systems*, 30. <https://arxiv.org/abs/1706.03762>

ANEXO A
PRIMER ANEXO

ANEXO B
SEGUNDO ANEXO

ANEXO C
TERCER ANEXO

